

科学模型专题（一）

深入理解神经网络原理与模型训练


李文毅

中国科学院软件研究所


中国科学院大学他山学科交叉创新协会

2026 年 09 月


什么是神经网络



AI蛋白质预测



AU合金纳米颗粒的设计



AI等离子体破裂预警



AI制药

例子：用已有数据预测新材料在新条件下的表现



- ① 已有样本：材料结构、温度 → 已测性质
- ② 训练：预测与真实值比较，反复调整内部参数
- ③ 使用：给定新材料或新温度，快速给出近似预测
- ④ 验证：再用实验或高精度计算检验预测

神经网络先从“有答案”的样本中学一个映射，再用它回答没见过的新样本


Agent vs 神经网络



神经网络的技术突破，推动了 AI 在科学领域的革命性应用，使科学研究范式发生根本性变革




AI蛋白质预测



AU合金纳米颗粒的设计



AI制药



AI等离子体破裂预警

从 LLM 到 Agent，AI 从能预测数据的神经网络，变成了会使用仪器的科研助手

什么是 Agent



LLM(Large Language Model)：一种处理语言为主的神经网络，能够根据上文预测出后一个词语

Agent：基于 LLM 的语言能力做感知、规划、工具调用等长程任务，可以搭 RAG、Skill、MCP 等工具

Harness：对多个 Agent、工具组成的系统进行组织调度



Agent 时代的科研流程

研究者：提出问题、设定边界、判断结论



Agent：拆解任务、调用工具、组织流程




神经网络：执行稳定、快速、可批量评测的预测

本节课的定位：
从原理上剖析神经网络，理解模型结构

先把书读厚，再把书读薄


开发者生涯



Agent vs 神经网络

代表性工作：2021 年提出的 AlphaFold2

- **网络架构**：采用端到端深度学习架构，从氨基酸序列直接预测三维结构；核心 Evoformer 通过自注意力捕捉长程相互作用，并以三角注意力进行空间推理
- **性能突破**：在 CASP14 竞赛中预测精度达原子级别，可与实验方法相媲美，被认为是解决了困扰生物学界 50 年的“蛋白质折叠问题”



Agent 可以调用、训练和组合模型；真正承载结构预测能力的，仍是专门训练过的模型及其参数



一个 Agent 时代的真实案例

现状与共识：Agent 时代的代码应该全权交给 Agent **吗？**



Agent 的输出：



代码能跑

无报错，跑完了



$R^2 = 0.94$

指标很漂亮



图很好看

散点几乎贴在对角线上

问题

- 这三项里有几项是真的？
- GNN 是什么网络？
- 为什么选择 GNN ？

Agent 时代，代码应该是在知道原理的情况下全权交给 Agent

提纲

CONTENTS

一、从线性回归理解学习的本质

二、神经网络的训练与优化

三、从线性模型到多层神经网络



从线性回归理解学习的本质

什么是线性回归？

- 问题引入：假设房屋销售中心有这样一组关于房屋面积和房屋位置与销售价格的数据，用 x_1 表示房屋面积， x_2 表示房屋楼层，...， y 表示售价（万元）
- 需求：设计一个程序进行预测 H100 号房屋的成交价

房屋编号	面积 m^2	楼层	朝向	房龄年	距地铁 km	成交价万元
H001	62	6	南	18	0.8	315
H002	89	18	南北	6	0.4	512
H003	75	4	缺失	12	1.6	356
H004	120	21	东	3	0.7	698
...						
H100	x_1	x_2	x_3	x_4	x_5	??

- 这是一个抽象的案例，在生物、化学、材料等领域可以有不同的变体

Sample • 样本

一行 = 一套房 / 一个完整研究对象

Feature • 特征

面积、楼层、朝向.....描述对象的信息

Label • 标签

成交价：模型希望回答的结果



数据处理与划分

➤ 数据处理：先把现实变成模型能比较的数字



朝向缺失怎么办？

南和南北怎样编码？

面积和楼层能直接比吗？

重复记录会不会被误以为更重要？

➤ 训练、验证、测试集划分：在学习之前，先留出没有看过的房子



训练集不是全部数据；测试集不能边看边改模型

原则：数据处理规则从训练数据确定，再应用到验证集和测试集





什么是线性回归?

线性回归可以找到一些点的集合背后的规律:

➤ 一个点集可以用**一条直线来拟合**, 这条拟合出来的直线的参数特征, 就是线性回归找到的点集背后的规律

$$\hat{y} = wx + b$$






从线性回归看「机器学习」的本质

一个模型，就是一组可以调节的参数

$\hat{y} = wx + b$ 不是一条固定的线，而是由 w 、 b 控制的一整族直线



w : 控制斜率

线旋转

b : 控制截距

线上下移动


训练和“学习”就是从所有参数中选出最优的一组参数



如何定义“最优”——loss 函数

损失函数定义：什么称为预测得好

每个样本都给出一个可见的误差：观测值与预测值之间的垂直距离



残差 residual

$$e_i = y_i - \hat{y}_i$$

每个样本都有一条误差线

一条线会同时产生很多个残差

- 损失函数：怎样把“很多个错”压成一个数字，告诉机器这条线到底好不好？

MSE (Mean Squared Error, 均方误差)

$$L(w, b) = \frac{1}{n} \sum_i (y_i - \hat{y}_i)^2$$




MSE 的直观表示

有了损失函数之后，同一组数据，三条候选线；机器只需要比较一个数字


$$L(w, b) = \frac{1}{n} \sum_i (y_i - \hat{y}_i)^2$$

Candidate A




MSE = 10.60

Candidate B



MSE = 1.29

Candidate C



MSE = 0.12


MSE 越小 → 模型拟合的误差越小 → 这组参数越好




梯度下降：根据 Loss 自动调整参数

换一个视角：从“数据空间”到“参数空间”

- 每一组 (w, b) 对应一条线，也对应一个 Loss。于是“选直线”变成“在地形上找最低点”。



$(w, b) \rightarrow L$





参数空间 / Loss Landscape

梯度下降：根据 Loss 自动调整参数

对于一个损失函数 $L(\theta)$ ，梯度就是“当前位置上，函数值上升最快的方向”

$$\nabla_{\theta} L = \left[\frac{\partial L}{\partial \theta_1}, \frac{\partial L}{\partial \theta_2}, \dots \right]$$

Gradient 告诉你：
“哪边上升最快？”




训练（梯度更新）：取反方向，就能让 Loss 下降

- 每一组 (w, b) 对应一条线，也对应一个 Loss
- “选直线”变成“在 loss landscape 上找最低点”

$$\theta \leftarrow \theta - \eta \nabla L(\theta)$$

新参数 = 旧参数 - 学习率 × 梯度





学习率：决定“一步走多远”

学习率决定每一步更新的大小

➤ 方向对了还不够：步子太小很慢，合适会收敛，太大可能反复越过最低点。




- η 太小
稳定，但要走很多步
- η 合适
较快接近最低点
- η 太大
震荡，甚至发散

“学习”不仅取决于模型和数据，也取决于优化过程本身

从线性回归看「机器学习」的本质

机器到底“学”了什么？—— 一组参数

- 对于线性回归模型来说，就是 (W, B) 这两个参数
- 对于 LLM 来说，参数有几百亿个
 - Qwen3-8B 中的 8B 表示有 80 亿个可以学习参数



模型怎么学的？—— 反向传播 + 梯度下降




训练 = 反复执行这个闭环，让参数逐渐变好

从线性回归到神经网络

世界不总是“简单相加”


➤ 拟合不好，可能是表达能力不够，而不是模型没有努力。

非线性




房龄 0→5 与 30→35 的影响不同

交互



同样 10 m², 地段不同增量不同

阈值




距地铁影响可能在某个距离后突变

非线性 + 交互 + 阈值 → 需要更有表达力的结构 → 多层神经网络

从神经元到多层感知机 MLP

一层神经元 → 多层感知机



- 深度、宽度和连接方式决定表达能力，也带来参数成本
- “特征之间的关系” “怎样组合多种特征” 也变成了训练问题。



从神经元到多层感知机 MLP

例子：手写数字识别

- 输入：一张手写数字的图片
- 输出：一个数字



从线性回归到神经网络


- 复杂度增加了几个数量级，但“参数化模型 → Loss → 梯度 → 更新”仍然是同一套骨架

$$\hat{y} = wx + b$$


两个参数

$$\hat{y} = f_{\theta}(x)$$


几十亿个参数



线性回归



浅层神经网络




深层神经网络 (DNN)

不同模型与归纳偏置

同一组证据，可以有多种合理的延伸方式


- 只见过少量样本时，许多不同规律都能解释已知数据；模型必须依赖某种默认偏好去回答未见输入。

偏好直线




已知点之外仍按相近斜率延伸

偏好平滑



允许弯曲，但相邻位置通常连续变化

允许突变



某个边界前后，规律可以突然改变

归纳偏置 = 数据之外的默认偏好，它决定模型更容易学到哪一种解释



先验知识如何变成归纳偏置

先验知识是什么？—— 在看完当前训练数据前已有的认识

- 例如：相邻像素通常更相关；原子编号不应改变分子性质；守恒量应满足方程

这里的“先验”指广义领域知识，不只指贝叶斯先验分布

归纳偏置是什么？—— 学习系统因此更偏好哪类答案



先验不会自动生效：写进数据表示、网络结构、Loss 或数据增强后，才成为归纳偏置



不同模型族，押注不同的数据结构

➤ **归纳偏置**的定义：模型在见到数据之前，就已经相信的东西

模型族	默认假设	写进系统的方式
线性回归	关系近似线性、可加	线性函数
MLP	固定长度向量；特征可全局交互	全连接 + 非线性
CNN	局部模式可复用；卷积层平移等变	局部感受野 + 权重共享
RNN / LSTM	顺序重要；状态转移规则沿时间复用	递归状态 + 时间共享
GNN	连接关系重要；节点编号不重要	消息传递 + 对称聚合
等变网络	旋转 / 平移时输出按规律变化	等变表示
Transformer	token 两两交互；顺序由位置注入	注意力 + 位置编码



先验越强 → 需要的数据越少，但先验错了就全错

先验越弱 → 越灵活，但需要的数据量指数上升

本章小结

Summary

一、学习的本质：调整模型的参数

二、神经网络的训练：反向传播与梯度下降

三、从线性模型到多层神经网络：归纳偏置

下节课预告

