

科学模型专题（二）

面向科学场景的数据理解与模型选型

李文毅

中国科学院软件研究所

中国科学院大学他山学科交叉创新协会

2026 年 09 月

回顾第一讲：一句 Prompt，已经替你做了多少未经验证的决定？



Agent 的输出

- ✓ **代码能跑**
无报错，训练结束
- ✓ **$R^2 = 0.94$**
数字看起来很漂亮
- ✓ **图很好看**
散点几乎贴着对角线

**但是：为什么是 GNN？
这个 R^2 真的代表科学上可用吗？**

这句话同时犯了两类错误：信息不足；还没理解数据，就先指定了模型



这句 Prompt 缺了什么？

1 目标

预测、排序、生成，还是找异常？

2 样本

一个分子、一个构型，还是一次测量？

3 表示

描述符、SMILES、2D 图，还是 3D 坐标？

4 规模

有效独立样本有多少？标签可靠吗？

5 先验

置换、旋转、守恒、局域性是否成立？

6 交付

只要分数，还是解释、不确定性与外推？

第一讲回答模型原理——“参数怎样学”
这一讲回答模型实操——“训练之前，Prompt 上必须先做对哪六个决定”



提纲

CONTENTS

一、典型网络结构：从 CNN 到 Transformer






二、科学数据的类型与表示

三、面向不同科学场景的模型选型方法

网络结构的本质：预先规定“谁和谁交换信息”

➤ 同一份数据，换一种连接方式，模型就会相信不同的关系

MLP	CNN	RNN	Transformer	GNN
全部特征	局部网格	前后位置	任意 token	相邻节点
怎样交流	怎样交流	怎样交流	怎样交流	怎样交流
全连接	共享卷积核	循环状态	注意力权重	沿边聚合
弱结构先验	局部性 + 平移共享	顺序 + 因果	数据依赖的全局连接	显式拓扑 + 置换不变



看到任何新架构，先问三件事：输入单元是什么？连接由谁定义？权重在哪里共享？



提纲

CONTENTS

一、典型网络结构：从 CNN 到 Transformer

二、科学数据的类型与表示

三、面向不同科学场景的模型选型方法

典型网络结构：从 CNN 到 Transformer



- 适合图像处理的卷积神经网络
- 适合语言 / 文本处理的循环神经网络
- 从深度学习到大模型
- 科学场景拓展


CNN 为什么出现：图像的邻近像素通常更相关

➤ 把图像拍平成向量，既丢空间邻域，又让第一层参数量随像素数膨胀

- 局部连接：先在小窗口内识别边缘与纹理
- 权重共享：同一个模式探测器可以扫过整张图

适合图像处理

CNN：卷积神经网络
(Convolutional Neural Networks)



全连接：位置各自拥有一套权重

数量级直觉

$$1024 \times 1024 \times 4096 \approx 4.3 \times 10^9$$



- MLP：把每个像素都连到每个隐藏单元
- CNN：只看邻域，并在位置间复用同一核
- 因此参数更少、先验更强

CNN 不是“更复杂的 MLP”，而是把图像的局部性与平移共享写进连接方式

CNN 的基本流水线：卷积、激活、汇总，再接任务头

每一层都在做同一件事：把局部证据变成更高层的表示

- 感受野随深度扩大：边缘 → 纹理 → 部件 → 对象



Input

0	1	2
3	4	5
6	7	8

Kernel

0	1
2	3

*

=

Output

19	25
37	43

窗口只读取邻域；同一卷积核滑过所有位置

CONV

局部特征

ReLU

加非线性

POOL / stride

下采样

HEAD

任务输出

感受野

堆叠小窗口，也能让深层单元看到大范围上下文

CNN 演进：每一代都在修正一个结构瓶颈

➤ 从“能提取局部特征”到“能稳定扩展、适应多尺度与更深网络”

1998

LeNet

卷积 + 下采样 + 分类头

把局部特征连成流水线

2012

AlexNet

ReLU • Dropout • GPU

让深 CNN 进入规模化训练

2014

VGG / Inception

小核堆叠 / 多尺度分支





更规整，或同时看多种尺度

2015

ResNet

残差捷径 $y = F(x) + x$

让信息与梯度走短路




CNN 变体的共同主线：扩大有效感受野，同时控制参数、优化难度与信息损失

视觉任务：输出长什么样，决定网络最后怎样读出答案

➤ 同样是图像输入，分类、检测、分割的答案形态完全不同


- 分类：一张图一个标签；
- 检测：位置 + 类别；
- 分割：每个像素一个标签

分类




• cat

整图 → 类别




检测




object

整图 → 框 + 类别




分割



mask

整图 → 像素标签图



检测器：定位 + 分类

Two-stage

Faster R-CNN
通常精度优先

One-stage

YOLO / SSD
通常速度优先

评价指标：IoU / mAP

先定义输出，再选模型：任务的答案形态比“输入是图像”更能决定架构



RNN：让状态沿序列流动，并在时间上共享参数

序列的核心不是“有很多列”，而是元素之间有顺序，当前判断依赖过去

- 同一组参数在每个时间步复用；隐藏状态 h_t 携带历史信息

适合语音 / 文本处理

**RNN：循环神经网络
(Recurrent Neural Networks)**



$$h_t = f(x_t, h_{t-1})$$

信息路径

- $t-1 \rightarrow t \rightarrow t+1$ ：一步一步传递
- 优点：天然尊重顺序与因果
- 代价：长距离依赖需要经过很多步

应用：语音 · 文本 · 视频 · 传感器流

RNN 的归纳偏置是“顺序 + 状态”；它把过去压缩进一个随时间更新的记忆

长依赖瓶颈：梯度链太长，LSTM / GRU 用门控制记忆

普通 RNN 反复乘同一类雅可比矩阵，容易出现梯度消失或爆炸


- LSTM (长短记忆网络, long short-term memory) : 独立记忆状态 + 遗忘 / 输入 / 输出门
- GRU (门控循环单元, gated recurrent unit) : 用更新门与重置门, 以更少状态完成类似控制

长链路

$$\mathbf{x}_1 \rightarrow \mathbf{h}_1 \rightarrow \mathbf{h}_2 \rightarrow \dots \rightarrow \mathbf{h}_t$$


梯度可能逐步变小或变大

LSTM



记忆状态 c_t 提供较稳定的传递通道

GRU




更新门：保留多少过去；重置门：重算多少当前

Seq2Seq 的转折：固定长度向量装不下整段输入


编码器把输入压成一个状态，解码器再逐步生成输出；序列变长后，瓶颈暴露

- Attention 让解码器在每一步直接读取所有编码状态
- 上下文向量随输出位置变化，而不是一次性固定

固定向量瓶颈



Attention：每一步重新选择上下文




Attention 把“记忆全部输入”的压力，从一个向量分散到每个输出步骤

Q / K / V : 自注意力让每个 token 动态选择上下文

同一序列中的每个位置，都可以根据当前任务决定“该听谁、听多少”

- Q：我在找什么？ K：我如何被匹配？ V：被选中后贡献什么？



$$\text{Attention}(\mathbf{Q}, \mathbf{K}, \mathbf{V}) = \text{softmax}(\mathbf{Q}\mathbf{K}^T / \sqrt{d_k}) \mathbf{V}$$

Q 查询向量 提出当前需求

K 键向量 提供匹配线索

V 值向量 携带被聚合内容


Multi-head：多组投影，从不同关系视角并行读取。

Transformer 的“全局”不是平均混合，而是由内容决定的加权连接

Transformer：注意力、FFN、残差与归一化的重复堆叠

Encoder 可整段并行；自回归 Decoder 训练时并行构造目标，推理时逐 token 生成

- 因果掩码保证每个位置只能看见已知 token；并非所有 Transformer 都必须自回归



Transformer 把“长距离依赖”从链式传播改成内容相关的全局连接，同时换来更好的训练并行度



从深度学习到大模型：架构之外，规模化训练成为新变量

大模型不是另一种神经元，而是 Transformer 在数据、参数、训练目标与对齐流程上的规模化

- BERT：双向编码，擅长理解；GPT：因果解码，擅长生成
- 预训练 → 指令微调 → 偏好对齐（如 RLHF）

两条代表性路线



GPT-1 → GPT-2 → GPT-3 → InstructGPT / ChatGPT → GPT-4

规模化闭环




能力随规模增长，但数据质量、评测与安全同样成为瓶颈。

理解“大模型”要同时看三件事：架构骨干、训练规模、以及把目标写进模型的方式

Transformer 也能看图：ViT、CLIP 与 BLIP-2 把模态接到 token 上

关键不是“图像变成文字”，而是为每种模态定义 token，并学习跨模态对齐

- ViT：patch $\rightarrow$ token；CLIP：图文对比学习；BLIP-2：视觉编码器 + Q-Former + 语言模型



ViT	图像 patch	视觉 token
CLIP	图像 $\leftrightarrow$ 文本	对比对齐
BLIP-2	视觉 $\leftrightarrow$ 语言	Q-Former 桥接

架构迁移：DETR（检测）• Swin（窗口层级）• DiT（扩散）

系统层扩展：Agent = LLM + 规划 / 记忆 / 工具


跨模态模型的共同语言仍是 Transformer：先把不同对象编码成可比较的 token

GNN：沿显式关系边传播消息

GNN 适合对象之间的关系本身就是数据的一部分：节点、边与属性共同定义样本

- message $\rightarrow$ aggregate $\rightarrow$ update ; 可做节点、边或整图预测

**GNN：图神经网络
(Graph Neural Networks)**



一层传播：每个节点只读取邻居的消息，再更新自己的表示。

NODE

对象属性

EDGE

关系类型 / 权重

READOUT

节点 / 边 / 整图

科学例子：分子、晶体、道路网、社交网。


GNN 的先验是显式拓扑：不沿边的对象，默认不会在这一层直接交换信息

PINN : 把 PDE / 守恒残差写进训练目标

PINN 的关键变化不在连接方式，而在 loss：数据误差之外，再惩罚物理方程残差

- 神经网络近似 $u \approx \hat{u}(x, t)$ ；自动微分得到导数；边界 / 初值与 PDE 一起约束

PINN : 物理信息神经网络
(Physics-Informed Neural Network)



$$L = L_{\text{data}} + \lambda \cdot L_{\text{PDE}} + \mu \cdot L_{\text{boundary}}$$

PDE 残差例

$$r_{\theta}(x, t) = \partial u_{\theta} / \partial t - \kappa \nabla^2 u_{\theta} - f$$

- λ / μ 平衡数据与物理约束
- 没有可靠方程时，PINN 先验可能变成错误约束

PINN 的选择依据是“有可微、可信的物理约束”，而不是数据看起来像图或像序列



第一章小结：从连接假设到科学场景扩展

➤ 模型选型的第一步不是搜索名字，而是识别数据结构与需要保留的先验

家族	自然输入	信息路径 / 先验	典型用途
MLP	固定长度向量	全连接；弱结构先验	表格 baseline
CNN	规则网格 / 图像	局部连接 + 权重共享	视觉、网格场
RNN / LSTM	有序序列	状态递推；门控记忆	语音、文本、时序
Transformer / ViT	token / patch	内容相关全局连接	理解、生成、跨模态
GNN	节点—边图	沿边消息传递	分子、晶体、网络
PINN	坐标 / 场	PDE / 守恒残差进 loss	物理场与逆问题

把“输入单元—连接方式—训练目标—验证边界”四件事说清楚，才有资格讨论模型大小

提纲

CONTENTS

一、典型网络结构：从 CNN 到 Transformer

二、科学数据的类型与表示

三、面向不同科学场景的模型选型方法

六类常见科学数据

➤ 同一个科学对象可能有多种表示；选择表示，就是选择保留哪一种关系

表格 / 矩阵

$N \times d$

行、列、单位

sepal length	sepal width	petal length	petal width	species
5.1	3.5	1.4	0.2	setosa
4.9	3.0	1.4	0.2	setosa
6.4	3.2	4.5	1.5	versicolor
5.9	3.0	5.1	1.8	virginica
5.7	2.8	4.1	1.3	versicolor

图像 / 网格

$H \times W \times C$


邻域、坐标、尺度



序列 / 光谱

$L \times d$


顺序、采样率、mask



关系图

$V / E /$ 属性


节点、边、拓扑



3D / 点云

坐标 + 类型


旋转、平移、排列



时空场

$X \times Y \times T \times$ 变量

边界、漂移、缺测



表格 / 矩阵：必须先说清每一行、每一列代表什么

sepal length	sepal width	petal length	petal width	species
5.1	3.5	1.4	0.2	setosa
4.9	3.0	1.4	0.2	setosa
6.4	3.2	4.5	1.5	versicolor
5.9	3.0	5.1	1.8	virginica
5.7	2.8	4.1	1.3	versicolor

1 一个样本是什么？

一株植物，还是一次测量？

2 结构在哪里？


行列标签、单位、稀疏性、批次与缺失

3 怎样划分？

重复测量与同一来源不能跨训练 / 测试

矩阵形状相同，不代表科学含义相同；行列语义与采集过程不能被“数值化”后遗忘

图像 / 规则网格：邻域由坐标定义，通道代表不同测量量



1 一个样本是什么？

一幅显微图、一个 3D 体，或一组输入—输出场？

2 结构在哪里？


相邻像素、空间尺度、通道、边界条件

3 怎样划分？

按样品、区域或实验条件，而非随机切像素

网格数据的关键不是“长得像图片”，而是空间坐标、局部邻域与多尺度是否有意义

序列 / 光谱：顺序、采样间隔与缺失位置都是数据的一部分



B

1 一个样本是什么？

一条序列、一段轨迹，还是一个固定窗口？

2 结构在哪里？



顺序、局部 motif、长程关系、采样率与 mask

3 怎样划分？

按家族、时间或实验批次，避免相邻片段泄漏

序列不能只看长度 L ；token 的含义、顺序与采样机制共同决定表示

关系图：节点与边的定义



1 一个样本是什么？

一张图、一个节点，还是一条边？

2 结构在哪里？




节点属性、边属性、周期边界与邻域半径

3 怎样划分？

按体系 / 结构族分组，检查图构造是否泄漏答案

图不是天然真理：邻居怎样连接、边表示什么，本身就是需要领域确认的建模假设

3D 几何：坐标系变了，答案应该保持还是随之变化？



1 一个样本是什么？

一个结构、一个构型，还是一段 3D 轨迹？

2 结构在哪里？



距离、角度、方向、周期边界与元素类型

3 怎样划分？

按结构家族 / 时间 / 体系；明确旋转和平移处理

3D 表示的核心是对称性：标量常要求不变，方向量则可能需要等变

时空场：空间邻域、时间顺序与变量通道必须同时定义



1 一个样本是什么？

一个时刻、一段窗口，还是一次完整事件？

2 结构在哪里？

站点 / 网格邻接、采样周期、预测窗口与外生变量。

3 怎样划分？

时间滚动 + 空间外推；不能随机打乱未来。

时空数据至少有两种结构；验证方案也必须同时回答“新时间”和“新地点”



把科学对象写成一张“数据表示说明书”

- | | | |
|----|-------|---------------------------|
| 01 | 样本单位 | 一条样本对应个体、实验、结构，还是时间窗口？ |
| 02 | 数据结构 | 向量、网格、序列、图、3D，还是多模态组合？ |
| 03 | 必须保留 | 局部邻域、顺序、拓扑、坐标、周期中哪些不能丢？ |
| 04 | 对称与变换 | 平移、旋转、排列、尺度变化后答案如何变化？ |
| 05 | 标签与质量 | 标签怎样得到？缺失、批次、单位与测量误差如何处理？ |

领域确认

说明书写清楚，后续模型选型才有可检查的依据



提纲

CONTENTS

一、典型网络结构：从 CNN 到 Transformer

二、科学数据的类型与表示

三、面向不同科学场景的模型选型方法

Agent 时代，模型选型六问就是建模 Prompt 的骨架

- 不要让 Agent 直接写训练代码



- 完成模型选型六问，得到建模需求说明书

建模需求说明书

【科学目标】从合金组分预测析氢反应过电势，用于从 5000 个候选组分中挑 20 个做实验。

【任务类型】回归，但真实用途是排序（Top-20 命中率优先于 RMSE）。

【一个样本】一条「组分占比 + 制备条件」记录；同一组分的重复实验属于同一组。

【数据结构】定长表格，13 维数值特征，无空间/时序/图结构
 => 不需要 CNN / RNN / GNN。

【数据】data/hea.csv, N=312；标签来自实验，重复性误差约 ± 15 mV。

【先验】组分之和为 1（约束）；无旋转对称性问题。

【数据划分】按「组分族」分组划分（同族不得跨集合），5 折交叉验证，报告 mean $\pm$ std。

【baseline】① 全局均值 ② 岭回归 ③ XGBoost ④ TabPFN。

【评价指标】主指标 Spearman ρ 与 Top-20 EF；
 辅助报 RMSE(mV) 并与 ± 15 mV 实验误差对比。

【交付】指标对照表 + 误差分析 + 特征重要性 + 明确说明结论属内插还是外推。

【禁止】不得使用随机划分；不得在全量数据上做标准化或特征选择。

模型选型六问

Q1 目标

Q2 样本

Q3 模态

Q4 数据量

Q5 先验

Q6 答案形状

数据审计

E_n	ω	ω_0	x	m
4.7	1.2	2.3	1.5	1.2
3.4	2.7	2.7	3.1	0.1
		$\vdots$		
2.8	1.5	3.6	1.4	0.4

候选 $\rightarrow$ 训练 $\rightarrow$ 验证
 $\rightarrow$ 诊断 $\rightarrow$ 再选择

模型选型方法

请 Agent 输出

baseline

候选族

划分 / 指标

风险

最终交付

报告

代码

不确定性

复现实验



模型选型六问 1 | 科学目标与任务类型？

1

先把“拟合”翻译成可验证任务

写进 Prompt

目标变量、科学用途、回归 / 分类 / 排序 / 生成 / 聚类 / 异常检测

决定模型选型的哪些方面

- 决定输出层、损失函数与指标
- 决定标签怎样构造，以及成功的科学含义

常见错误

把“筛选优先级”当成“数值回归”做

简单例子：药物候选筛选关心前 1% 排名；即使 RMSE 尚可，排序也可能很差

任务不是数据集自带的标签名，而是你准备怎样使用答案



模型选型六问 2 | “一个样本”是什么？

2

有效样本量 N 与划分单位必须一起写

写进 Prompt

一个分子 / 构型 / 病人 / 样品 / 实验 / 时间窗口；哪些对象必须分组划分

决定模型选型的哪些方面

- 决定有效独立样本数，而非文件行数
- 决定训练 / 验证 / 测试是否真正独立

常见错误

把同一体系 1000 个构型当成 1000 个独立样本

简单例子：同一病人的多张切片若跨训练与测试，模型可能只认出了病人。

不先定义科学独立性，再统计 N；否则漂亮指标可能只是同源泄漏



模型选型六问 3 | 数据模态与内在结构?

3

写清数据元素、关系与表示

写进 Prompt

表格 / 图像 / 时序 / 图 / 序列 / 谱 / 场; 邻接、顺序、坐标、多模态关系

决定模型选型的哪些方面

- 决定候选架构族与 token / 节点 / 像素定义
- 决定哪些关系必须保留、哪些变换不应改变语义

常见错误

把有结构的数据拍平成表格，丢结构等于丢先验

简单例子：分子可表示为描述符、SMILES、2D 图或 3D 坐标；候选模型随表示改变。

数据模态不是文件格式；真正重要的是内部关系怎样进入计算



模型选型六问 4 | 多少数据、多少标签?

4

报告有效 N、维度、噪声与标注成本

写进 Prompt

独立样本数、标签比例、缺失、重复、测量误差、类别不平衡、预训练资源

决定模型选型的哪些方面

- 决定模型容量、正则化与是否需要预训练
- 决定能负担多弱的归纳偏置与多复杂的验证

常见错误

N = 200 时从头训练一个大型 Transformer

简单例子：小数据表格先比较线性 / 树模型；结构明确时再尝试更强先验网络。

样本少时，正确先验与可靠验证通常比增加参数更值钱



模型选型六问 5 | 你知道哪些科学先验?

5

把不会改变的规律写进模型或约束

写进 Prompt

对称性、守恒量、单调性、局域性、周期边界、机理方程、已知不可行区域

决定模型选型的哪些方面

- 缩小假设空间，提高数据效率与外推可信度
- 决定是否需要等变网络、约束损失或机理耦合

常见错误

明知旋转 / 置换规律存在，却让普通 MLP 重新从数据里猜

简单例子：刚性旋转一个 3D 结构，标量能量应保持，力的方向则应随坐标一起旋转。

科学家相对纯 AI 工程师的优势，不只是数据，而是知道哪些规律绝不该被违反



模型选型六问 6 | 答案要长什么样？

6

精度之外，还要定义怎样被相信和使用

写进 Prompt

可解释性、不确定性、推理成本、内插 / 外推、部署延迟、失败时如何报警

决定模型选型的哪些方面

- 决定是否接受黑箱，以及是否需要 GP、集成或校准
- 决定验证集应模拟哪一种未来使用场景

常见错误

需要机理解释时，只交付一个黑箱分数

简单例子：实验排队资源有限时，模型应同时给预测与不确定性，帮助决定下一次测什么。

模型选型的终点不是排行榜第一，而是得到一个在目标场景中可用、可信的答案

《模型选型六问》决策卡：训练开始前逐项回答



#	必答问题	决定模型选型的哪部分	常见错误
1	科学目标与任务类型？ 回归、分类、排序、生成、聚类、异常检测	决定输出、损失函数与指标	把筛选（排序）当预测（回归）做
2	“一个样本”是什么？ 分子、构型、病人、样品、实验	决定有效 N 与划分单位	把同体系 1000 个构型当独立样本
3	数据模态与内在结构？ 表格、图像、时序、图、序列、谱、场	决定候选架构族与表示	把有结构的数据拍平成表格
4	多少数据、多少标签？ N、维度、噪声、标注成本	决定容量、先验强度与验证负担	N=200 上从头训练大型 Transformer
5	你知道哪些科学先验？ 对称、守恒、单调、机理方程	决定约束、等变性与数据效率	已知规律不写入模型，白花数据
6	答案要长什么样？ 精度、解释、不确定性、内插 / 外推	决定黑箱可否接受与交付方式	需要机理解释时只交付黑箱

从“指定一个 GNN”到“让 Agent 先完成选型论证”

原 Prompt



未说明：目标、样本、表示、规模、先验、交付
提前指定：GNN

容易得到：能跑的代码 + 漂亮但不可审计的分数

六问版 Prompt（示例骨架）

请先不要直接写训练代码；若信息不足，先列出需要我或领域专家确认的问题。

- Q1 目标** 预测 [具体性质]，属于 [回归 / 分类 / 排序]；科学用途是 [筛选 / 定量 / 解释]。
- Q2 样本** 确认一行对应分子还是构型；同一实体必须分组划分。
- Q3 模态** 比较描述符、SMILES、2D 图、3D 坐标各自保留 / 丢失的信息。
- Q4 规模** 报告有效独立 N、标签数、缺失、噪声与重复；不要把同源记录当独立样本。
- Q5 先验** 确认置换、旋转 / 平移不变或等变、局域性与其他机理约束。
- Q6 交付** 除精度外报告不确定性、外推、可解释性与推理成本。

请输出：数据审计 → baseline → 候选模型族与理由 → 划分 / 指标 → 风险与复现实验。

Agent 可以替你实现模型代码；“选型六问”负责让它实现的是一个定义清楚、可验证的科学任务



课堂实训：用六问把自己的数据写成一份建模任务书

5 分钟小组任务

1. 科学目标 / 任务：_____
2. 一个样本与划分单位：_____
3. 数据模态与必须保留的结构：_____
4. 有效 N、标签与噪声：_____
5. 已知科学先验：_____
6. 期望交付与外推边界：_____

汇报只说三句话

- 1 我的数据最像 _____，
必须保留 _____。
- 2 我的最小 baseline 是 _____；
第一候选模型族是 _____。
- 3 验证必须按 _____ 切分；
若 _____，我才升级模型。



总结

SUMMARY

一、模型结构的本质是规定谁和谁交换信息

二、数据形式代表主动保留什么科学关系

三、在 Agent 时代，把科学问题定义正确是更重要的事情
