




中国科学院大学

University of Chinese Academy of Sciences

从零搭建智能体



Agent = Model + Harness

主讲人：陈希鸿 中国科学院大学 博士研究生

培养单位：中国科学院西双版纳热带植物园

联培单位：中国科学院自动化研究所

Nature 论文 (2026.3.25) : Towards end-to-end automation of AI research

核心成果: AI Scientist 一个端到端科研智能体系统


[View](#)

[Explore content](#) [About the journal](#) [Publish with us](#)

[nature](#) > [articles](#) > [article](#)

Article | [Open access](#) | Published: 25 March 2026

Towards end-to-end automation of AI research

[Chris Lu](#), [Cong Lu](#), [Robert Tjarko Lange](#), [Yutaro Yamada](#) , [Shengran Hu](#), [Jakob Foerster](#), [David Ha](#)  & [Jeff Clune](#) 


[Nature](#) **651**, 914–919 (2026) | [Cite this article](#)

 [Save article](#)

391k Accesses | **122** Citations | **854** Altmetric | [Metrics](#)

Abstract

The automation of science is a long-standing ambition in artificial intelligence (AI) research^{1,2}. Although the community has made substantial progress in automating individual components of the scientific process, a system that autonomously navigates the entire research life cycle—from conception to publication—has remained out of reach. Here we present a pipeline for automating the entire scientific process end to end. We present The AI Scientist, which creates research ideas, writes code, runs experiments, plots and analyses data, writes the entire scientific manuscript, and performs its own peer review. Its ideas, execution and presentation are of sufficient quality that the manuscript generated by this AI system passed the first round of peer review for a workshop of a top-tier machine learning conference. The workshop had an acceptance rate of 70%. Our system leverages modern foundation models^{3,4,5} within a complex agentic system. We evaluate




什么是 Agent ?




LLM（大语言模型）：经海量语料预训练，具备语言理解与生成能力的**神经网络模型**。

Agent（智能体）：感知环境并作用于环境的**实体**。

Harness（驾驭层）：承担运行调度、能力扩展、安全约束和效果保障的工程化**支持框架**。




2022 年 12 月使用 LLM 的模式



LLM 的两个重要特性

上下文限制

- 一次能读进去的文字有限（上下文窗口）
- 每次调用都是一次性的，前面对话要重新拼进输入



超出窗口会被截断

幻觉


- 知识止于训练数据，之后的事它没见过
- 没见过的东西，它照样答得流畅，真假要靠工具核实

标题： _____
作者： _____
年份： _____
期刊： _____
摘要： _____

论文可能并不存在


Agent 是如何运行的?

理想中:




Agent 是如何运行的?

实际上 (可能) :




Agent 是如何运行的?

优化后效果:




Agent 是如何运行的?

实际实现的手段（可能）：




Agent 是如何运行的?

继续优化:



Agent 是如何运行的?

进一步优化:




什么是 Agent？什么是 Harness？

Agent=Model+Harness


S：

(非学术定义)

协助完成指令：考试考到100分




什么是 Agent？什么是 Harness？



学校 (Multi-Agent System) $\approx$ 人 (Agent) + 教育运行体系 (Harness)

什么是 Agent？什么是 Harness？


以学生的学习过程作功能类比



$$\text{Agent} = \text{Model} + \text{Harness}$$

什么是 Agent？什么是 Harness？


以大语言模型（LLM）驱动的智能体为例



$$\text{Agent} = \text{Model} + \text{Harness}$$


Agent 是如何运行的?

以文献检索为例




Agent 是如何运行的？

以文献检索为例



Agent 是如何运行的?

以文献检索为例



Agent 是如何运行的？


以文献检索为例

概念	主要作用	文献综述中的例子
模型（Model）	理解信息、推理和生成内容	判断文献相关性，选择下一步行动
工具（Tool）	执行检索、读取或保存等操作	检索数据库、读取 PDF、保存文件
技能（Skill）	提供操作方法、脚本和资源	检索方法、筛选规则、引用核验要求
工作流（Workflow）	规定任务的步骤和执行顺序	检索、筛选、阅读、写作、核验
运行框架（Harness）	管理模型调用与任务执行	整理上下文、调用工具、保存运行记录
智能体（Agent）	根据任务采取行动	多次检索文献，完成资料查找

Agent 是如何运行的?

以文献综述 agent 为例:

查资料 这一步是如何实现的?




Agent 是如何运行的?

以文献综述 agent 为例:

查资料 这一步是如何实现的?

调用 网络搜索 tool 失败了如何处理?




Agent 是如何运行的?

以文献综述 agent 为例:

查资料 这一步是如何实现的?

调用 网络搜索 tool 失败了如何处理?

变通 调用 API



Agent 是如何运行的？


运行循环（示意）

Harness

- 1 准备任务、工具说明和已有记录
- 2 在权限、次数和时间限制内循环：
- 3 调用模型，获取回答或工具请求
- 4 如有工具请求：执行调用，更新上下文，继续循环
- 5 如满足完成条件：输出结果，结束
- 6 如需人工处理：暂停，并说明原因
- 7 其他情况：补充信息，继续执行
- 8 达到运行限制时：停止并报告当前进度


Agent 的运行循环

推理、行动与观察 (ReAct)



Agent 的运行循环


推理、行动与观察 (ReAct)



Workflow 与 Agent 运行循环


工作流 (Workflow)

预先规定步骤与分支



Agent 运行循环

运行中选择下一步操作



AGENT = MODEL + HARNESS

HARNESS 让 Agent 在真实场景中持续工作

模型是 Agent 的灵魂。

Harness 给予 Agent 理解环境、使用工具，并在真实场景中持续工作的能力。



Cordis 内核

CORDIS KERNEL

Cordis 内核只负责插件的加载、卸载和依赖关系，不承载 Agent 的具体能力。



插件提供能力

CAPABILITIES AS PLUGINS

模型、工具、技能、会话、沙箱、存储、循环、调度、UI 等所有 Agent 能力均由插件提供，并通过 Cordis 服务与事件彼此协作。



配置层自由组合

COMPOSE IN CONFIGURATION

开发者无需改动源码，即可在配置层选择、替换或扩展任一能力。

DeepSeek Harness：4 种模式与创造模式的用法

DeepSeek 开源的智能体运行框架，模型、工具与 workflows 能力由插件组合

4 种预设模式

模式	能力与适用场景
标准模式	完整工具组合 适合日常编程与任务执行
PTC 模式	用一段代码组合多步工具调用 适合批量操作与多步编排
极简模式	仅 Shell 与文件编辑工具 适合最小环境下的模型评测
创造模式	检查运行时，试验和组合插件 用于创建自定义智能体预设

创造模式：创建可复用的智能体


- 1 启动并配置**
npx @deepseek-ai/dsh web
在“设置 / 模型”填 API Key，选择工作区。
- 2 选择“创造模式”**
新建会话，说明任务、工具、流程与交付物。
- 3 检查、试验并保存**
检查运行时，试验插件，保存为新的智能体预设。
- 4 在新会话中复用**
选择新预设，用小任务核对结果与执行轨迹。

创造模式提示词示例

请创建一个“文献综述智能体”：检索文献、提取证据、撰写综述并核验引用。
复用已有工具与技能，试验缺失插件，保存为新预设，并用一个主题验证。

从零搭建智能体

基于 DeepSeek Harness 复现 AI Scientist



从零搭建智能体

创造模式展示（开始）

🔗 工作流

用户对话

4

第1轮：第1轮：论文与源... 06:48:36

24次模型调用 · 32次工具

✅ 已完成

第2轮：第2轮：在 Dee... 06:54:24

39次模型调用 · 41次工具

✅ 已完成

第3轮：第3轮：检查实... 07:04:14

13次模型调用 · 12次工具

✅ 已完成

第4轮：第4轮：依据独... 07:19:49

40次模型调用 · 40次工具

✅ 已完成

第1轮：第1轮：论文与源码分析，建立本次科研实操...

🕒 06:48:36 5m20s 24次模型调用 32次工具

模型调用 #1

🕒 06:48:36 3.5s 输入 10,693 输出 317 ✅ 已完成

REQUEST 请求

glm-5.3

System 1 消息 3 工具定义 26

RESPONSE 响应

Let me start by exploring the local s...

Reasoning 1 Content 0 工具调用 2

bash

{ "command": "git log -1 --format='...' }

✅ 0c09329ea400247f2e6fb... 58ms

bash

{ "command": "ls -la && ls ai_scienti..." }

✅ total 184 drwxr-xr-x@ 17 ... 13ms

请求详情

系统提示词

```
{ } JSON
{
  "system": "You are an AI agent powered by DeepSeek Harness.\n\nThe DeepSeek Harness implementation checkout is at /Applications/DSH Workflow.app/Contents/Resources/dsh-runtime/. The checkout location and current working directory are separate values and may differ; never infer the working directory from this path. Use pwd to
```

消息

```
{ } JSON
Scientist-v2 的主要研究机制：研究假设、四阶段实验搜索、真实执行反馈、实验记录、写作与独立评审。我们采用 CPU 上可复跑的小规模数值实验。应称为“研究流程与关键机制复现”，明确与原论文训练规模和数据集的差别。
\n\n拟定研究问题：小样本非线性回归中，增加多项式阶数与正则化强度，能否同时改善预测误差和跨随机种子的稳定性？数据生成机制事先固定，含已知非线性和噪
```

工具定义

```
{ } JSON
{
  "tools": [
    {
      "name": "ask_user_question",
      "description": "Ask the user a concise question when you need confirmation, a choice, or missing information before proceeding. Send one or more questions, each with a stable id that will be echoed in the answer.",
```

从零搭建智能体

创造模式展示（结束）

🔗 工作流

用户对话

4

第1轮：第1轮：论文与源... 06:48:36

24次模型调用 · 32次工具

✅ 已完成

第2轮：第2轮：在 Dee... 06:54:24

39次模型调用 · 41次工具

✅ 已完成

第3轮：第3轮：检查实... 07:04:14

13次模型调用 · 12次工具

✅ 已完成

第4轮：第4轮：依据独... 07:19:49

40次模型调用 · 40次工具

✅ 已完成

模型调用 #23

🕒 06:53:39 8.4s 输入 104,571 | 未缓存 4,091 | 缓存命中 100,480 输出 370 ✅ 已完成

🚩 REQUEST 请求

glm-5.3

System 1 消息 57 工具定义 26

📄 RESPONSE 响应

The skill catalog now shows my ne...

Reasoning 1 Content 0 工具调用 1

🔧 bash

{ "command": "python3 -c \"import j...

✅ JSON OK: 1.0.0-frozen | st... 50ms

模型调用 #24

🕒 06:53:48 7.5s 输入 105,082 | 未缓存 570 | 缓存命中 104,512 输出 686 ✅ 已完成

🚩 REQUEST 请求

glm-5.3

System 1 消息 59 工具定义 26

📄 RESPONSE 响应

第 1 轮完成。已核上游源码 (HEAD ...

Reasoning 1 Content 1 工具调用 0

📄 最终回复

响应详情

Reasoning

All four files written and validated. Now the final concise Chinese report: files written + scope of this reproduction. Avoid "不是.....而是....." pattern, no promotional summary, no long thinking.

Content

第 1 轮完成。已核上游源码 (HEAD `0c09329e`, merge-base `96bd516`) 与本地 PDF (68 页预印本, 即 Nature 引文的同一系统), 本轮未运行任何实验。

****已写入的文件****

- `source\_mapping.md`: 系统步骤与上游文件/函数的逐条映射 (含行号)。核实要点: 四阶段在代码中为 `initial\_implementation / baseline\_tuning / creative\_research / ablation\_studies` (agent_manager.py:149-154), 论文措辞为 Preliminary Investigation / Hyperparameter Tuning / Research Agenda Execution / Ablation Studies: 20/12/12/18 的语义是 ****Journal 节点数上限**** (`len(journal.nodes) >= max\_iters`), 每 step 并行追加最多 4 节点故可向上

响应指标

json

复制

```
{
  "timingRecorded": true,
  "stepStartTime": 1788562428329,
  "firstTokenTime": 1788562429791,
  "completedTime": 1788562435808,
  "usageProvided": true,
  "outputTokens": 686
}
```

从零搭建智能体

搭建完成

创建科研预设

复制标准模式

配置 ecs-* 科研技能

组织科研流程

提出假设，运行代码与实验
绘图、撰写短论文、评审修订

保留证据链

记录真实指标和图表数据
以证据账本、检查点追踪过程

📁 AI Scientist-v2 科研实操 ▾

描述你想要构建的内容

+

🕒 Full access ▾

标准模式

功能完整的编码 Agent，支持文件编辑、Shell、文件与网页检索、Skills、计划、目标、子代理和工作流。

PTC 模式

具备标准模式的全部能力，并通过 Code Mode SDK 呈现工具，让模型用一个 TypeScript 程序组合多步操作。

极简模式

仅提供持久 bash 与 str_replace_editor 的双工具编码 Agent。

创造模式

用于创建自定义 Agent preset：具备标准模式的全部能力，并提供运行时检查、插件实验和 preset 创作指导。

证据链科学家

证据链科学家（Evidence-Chain Scientist）：
DeepSeek Harness 原生科研自动化代理。复现并改进 AI Scientist v2 的端到端闭环（中文主题→可证伪假设→实验→运行代码→真实指标→绘图→中文短论文→独立评审→修订），以证据账本、阶段检查点、图表数据清单与事务式论文写入保证结果可溯源、可恢复、可审计。自 standard preset 复制修改，附 ecs-* 技能。

GLM-5.3 ▾

↑



谢谢！ 欢迎批评指正