

智能体知识库与记忆

让 AI 从「查档案」到「记得你」

余宣庆

中国科学院自动化研究所

中国科学院大学学科交叉创新协会



余宣庆

中科院自动化所

工业智能团队 TiMEM 太忆创始人

知识图谱 · 大模型推理 · 记忆机制

TiMEM：工业级时序记忆 + 智能体集成

让 AI 记住你一个月的实验过程，
换台电脑、换个工具，它依然认识你。



发表 7 篇 ACL / EMNLP 论文

方向：大模型 · 知识图谱 · 记忆推理



担任 ACL 审稿人

持续跟踪大模型与记忆方向的研究前沿



第一批研究 Agent Memory 并产业化落地的团队

从论文到产品，完整走通工程闭环



当前关注：工业等真实落地场景

Agent Memory 驱动的持续学习

你的 AI，还记得你吗？



现实：大模型的参数训练完就冻结了——你的资料、偏好和项目进展，它一概不知道。

破局：落地必须给它外挂两样东西——**知识库（查得到）**和**记忆（记得你）**。

现状：有人已开始用「文件夹」凑合，但还不够好。



期望的效果：你的资料随时查得准，你的习惯与进展它一直记得——这就是知识库 + 记忆。

你现在的做法，其实已经走了一半



现状：文件夹 + AI 助手管理文献

按章节分夹：绪论一夹、方法一夹、正文一夹

AI 只看得到标题，**没读过内容**

每次全量重读→慢、费 Token、定位不准

本质也是一种「**检索增强**」

——没分块、没索引

知识库的做法

文献提前解析、切分成片段

提问时**精准召回**对应片段，不用全量重读

毫秒级检索，答案**可溯源**到原文段落

把你已有的习惯，做到位

本次分享聚焦的四个核心问题



1

RAG 是什么

为什么科研需要它

2

记忆是什么

与 RAG 有什么区别

3

课题里怎么用

哪个环节、解决什么问题

4

工具怎么选

有哪些、各自适合什么

为你的科研工作流，找到可落地的知识库与记忆方案。

01

知识库与 RAG：让 AI 查得到

从本地文献到「每句话都有引用」的答案



本地 200 篇文献，AI 却 " 没读过 "



1 知识过时

大模型知识截止到训练日期，无法回答最新进展。

2 私有盲区

你的 PDF 是私有的，大模型在预训练时从来没见过。

3 幻觉问题

一次性塞入太多上下文，模型会 " 胡说八道 " 或丢失重点。



嵌入

Embedding

将文本转化为高维向量，让 AI 理解语义
——把「意思」翻译成「坐标」

召回

Recall

从知识库中检索并提取相关片段返回给大模型

重排序

Rerank

对召回结果二次精排，把最相关的内容排到最前，提升相关性

检索

Retrieve

广义的信息查找过程，
是包含召回、重排等步骤的整套动作

先记住这四个词，后面的流程图就不会卡住。

建库：把论文变成“高维坐标”



1. 切分 Chunk


PDF → 500 字小段文本

2. 向量化 Embedding

文本 → 768 维向量


3. 存储 Vector DB

向量 → 向量数据库



向量就像图书馆的索引卡片——意思相近的论文，在语义坐标空间里“挨得近”。

检索：从问题找到论文




检索不是简单的关键词匹配，而是基于语义距离的精准定位。

智能体内部，信息怎么流转？



外循环（工具调用）



内循环（上下文组装与生成）

LLM 这一次看到的完整上下文 (Context Window)




外循环 = 找资料，内循环 = 拼上下文。

实例：从 PDF 到答案



1 上传文献并切分



2 用户提问

"这篇综述对比了哪几种聚类算法?"



3 系统召回关联片段

K-Means 需要预先指定 K 值 ... ← 来源：P.12

DBSCAN 基于密度，能发现任意形状 ... ← 来源：P.15

层次聚类分为凝聚式和分裂式 ... ← 来源：P.18

4 AI 总结并回答

综述主要对比了三种聚类算法：

- K-Means (基于划分) [1]
- DBSCAN (基于密度) [2]
- 层次聚类 [3]

✓所有陈述均有文献出处，拒绝幻觉

基于 RAG 的回答不仅精准，更重要的是每句话都可溯源、可审计。

演示：太忆空间
——建库、上传、带引用问答

传统 RAG vs Agentic RAG



传统 RAG：像“图书管理员”

你要什么书，立刻找出来，拼进提示词。
它是**线性、单向**的流水线，不负责复杂的逻辑推理与自我修正。




Agentic RAG：像“研究助手”

分析你的意图，规划检索路径。第一次没找到？
换个关键词再搜。它是**循环、多步、主动规划**的智能代理。



Agent 调用服务时序架构



本地部署与最小闭环：亲手跑通一个 RAG



课上：演示效果 | 课后作业：30 分钟手搓

三个组件，零安装

LangChain 编排流程
Notebook / 命令行即可运行

智谱 Embedding 公开接口
本地跑不动模型？直接用 API

FAISS 向量库
LangChain 自动加载，免单独安装

五步闭环：拿你自己的 PDF/Word 跑通



课上：演示五步闭环完整效果

课后作业：30 分钟，用你自己的 PDF / Word 手搓一个 RAG

备用材料：示例 PDF 与接口 Key 发群，代码包见 GitHub（链接在课后资源页）

跑通一次，胜过听讲十遍——上半场的原理图，现在变成你手里的代码。

本地部署与最小闭环：亲手跑通一个 RAG



工单 合并请求 里程碑 探索

yuxuanqing / RAG-Memory-demo

<> 代码

工单

合并请求

workflow

软件包

项目

发布

百科

活动

1 提交

1 分支

0 Git 标签

main

转到文件

添加文件

<> 代码

JoanhLan 和 Cursor

bc63b26de8

Add RAG and TiMEM memory demo with README.

...

16小时前

data	Add RAG and TiMEM memory demo with README.	16小时前
scripts	Add RAG and TiMEM memory demo with README.	16小时前
.env.example	Add RAG and TiMEM memory demo with README.	16小时前
.gitignore	Add RAG and TiMEM memory demo with README.	16小时前
rag_demo.ipynb	Add RAG and TiMEM memory demo with README.	16小时前
rag_demo.py	Add RAG and TiMEM memory demo with README.	16小时前
rag_timem_demo.ipynb	Add RAG and TiMEM memory demo with README.	16小时前
rag_timem_demo.py	Add RAG and TiMEM memory demo with README.	16小时前
README.md	Add RAG and TiMEM memory demo with README.	16小时前
requirements.txt	Add RAG and TiMEM memory demo with README.	16小时前
run_timem_demo.bat	Add RAG and TiMEM memory demo with README.	16小时前

效果不好？瓶颈不在检索，在数据



现场高频现象


化学式、公式类提问召回失败
表格内容答非所问
扫描版 PDF 几乎搜不到

归因

效果上限由**数据预处理**决定
不在检索算法、不在模型大小
垃圾进，垃圾出

工具：MinerU

PDF → 结构化 Markdown
公式、表格识别准确
解析结果可直接入库



垃圾进，垃圾出——所以预处理比算法更重要：输入质量做到位，后面水到渠成。

预处理之后：成熟工具一键管理



演示：跳出 PPT → 现场建库问答

预处理好的文件，成熟工具（以 TiMEM Space 为例）一键上传即可

①创建主题库

②上传自动解析

③问答带引用溯源

④共享给团队协作

配套能力

 笔记功能：实验记录随手沉淀

 库管理：导入 / 导出 / 移动 / 重命名

⚠如果边界封闭？

知识只能在它内部问答使用
能否让知识被「所有」智能体取用？
——MCP 连接器

手搓理解原理，工具解决日常——两条路都要知道在哪。

预处理之后：知识库助手一键管理



TIMEM

记忆

对话

连接

知识库

设置

帮助

管理

4 个知识库 · 16 个文件 · 900 个知识片段

知识库4 个

制造业企业... 0

装修质检 1

科研论文参考 15

默认知识库 0

Q 搜索文件...

已用 38 MB / 1.0 GB · 16/20 文件

timem_1231.pdf

69 片段

6.0 MB

2026/08/28

6733_MemCtrl_U...

50 片段

5.8 MB

2026/08/28

output.pdf

66 片段

4.8 MB

2026/08/28

2601.02845v1.pdf

65 片段

5.0 MB

2026/08/28

source.pdf

61 片段

2.9 MB

2026/08/28

MMG_manuscrip...

61 片段

2.9 MB

2026/08/28

8048_GCIG_Grap...

53 片段

1.9 MB

2026/08/28

EventPuzzle.pdf

54 片段

1.7 MB

2026/08/28

ONSEP-Poster-A...

4 片段

1009 KB

2026/08/28

2311.07032v2.pdf

58 片段

1.1 MB

2026/08/28

9467_CWM_Cont...

74 片段

662 KB

2026/08/28

3526_Cluster_R1...

98 片段

797 KB

2026/08/28

1133_ONSEP_A_N...

62 片段

1.2 MB

2026/08/28

2025.findings-ac...

65 片段

329 KB

2026/08/28

365_ItD_Large_L...

45 片段

682 KB

2026/08/28

切分 Chunk

overlap 重叠窗口设计,
避免语义被切断

Embedding 选型与微调

单模态 vs 多模态;
垂直领域可微调

Reranker 重排序

召回之后再精排,
显著降低噪音

向量库选型

Milvus / PGVector / ZVec ,
企业级部署选项

GraphRAG / LightRAG

图结构管理知识, 面向多跳推理

课后资料包

开源代码 + 部署教程 + 手把手接
入文档, 群内分发

这些名词今天不展开——遇到效果瓶颈时, 回来按这张图逐项排查。

为什么 RAG 还不够？



静态的

PDF 上传入库后内容就不再生长，
不手动更新，知识永远停在昨天。



无状态的

不关心你是谁，每次查询都从零开始，
不理解你的上下文。



无时间的

不知道「上周」和「现在」的区别，
更不知道两者之间的因果。

RAG = 档案柜

上传 → 切片 → 查档案 → 回答

放进去什么，才能查到什么——档案不会自己长出来。


记忆 = 人脑

交互 → 自动摘要 → 时间线整理 → 冲突处理 → 人格画像

今天说的话，明天会和上周的话做交叉比对——越用越懂你。

RAG 让 AI 能「查档案」，但档案不会自己生长；记忆让 AI 能「长脑子」，越用越懂你。

RAG 能「查资料」，但不「记得你」



「根据我的实验和文献，下一步试什么？」——文献找 RAG，实验找记忆，拼出答案

图书馆谁进去借都一样；笔记本上全是你的笔迹——协同区，就是两者一起回答你的问题。

RAG vs 记忆：一张表看懂分工



维度	RAG（查资料）	记忆（记经历）
管理对象	静态的、公共的知识（文献、PDF、公共资料）	你的交互历史、决策与实验进展
关心「你」吗	不关心你是谁，谁查都一样	动态的、个人的、有上下文依赖
数据更新	需主动上传新 PDF 才会更新	每次对话自动写入、自动提炼
典型问题	「K-Means 原理是什么？」	「我习惯用什么预处理方法？」

RAG 等同于图书馆的检索系统，而记忆则是你个人的实验笔记本。

02

智能体记忆：让 AI 记得你

三种存储形态 · 时序分层 · 写入与读取的完整代谢



记忆的三种 “存储形态”



知识库型


像图书馆，静态、只读
向量库 / 静态领域图谱 / PDF



.md .json

文档型

像笔记本，记录交互历史
Markdown / 文本 / JSON



图谱型

像思维导图，随交互动态生长
记忆图谱：实体 - 关系 - 实体

统一检索层：RAG

RAG 是一种统一的检索方法，而非记忆本身的存储类型。

```
memories/  
  user_alice/  
    profile.md  
    2026-08-28.md  
    project_timem.md
```


#profile.md 内容片段

- 姓名：Alice
- 偏好：极简设计、深色模式
- 职业：前端工程师

核心特征：白盒化、强结构

- **优点：完全人类可读可编辑**
 - 你甚至可以直接用 VS Code 打开修改它。
 - 支持 Git 版本控制，排错时一目了然。
- **优点：精准控制上下文**
 - 适合把整个 `profile.md` 直接塞入 System Prompt，
 - 作为全局 System Message。
- **缺点：缺乏语义检索能力**
 - 检索只能依赖关键字匹配或正则，无法通过近似含义（如“寻找关于投资的讨论”）召回。
- **缺点：规模瓶颈**
 - 随着历史记录无限增长，单个文件会变得极其臃肿，
 - 超出 Prompt Token 上限。

记忆形态二：高维向量化存储



核心特征：浮点数黑盒、算力驱动


- **优点：强大的模糊与语义匹配**
 - 通过计算 Cosine 距离，无论你说“苹果”还是“Apple”，系统都能召回相关记录。
- **优点：无惧海量数据**
 - 适合存储长达数年的碎片化历史记录，
 - 通过近似最近邻（ANN）实现毫秒级召回。
- **缺点：人类不可读**
 - 纯数字数组，无法直观浏览或手工排错。
- **缺点：修改成本高**
 - 无法像编辑文件那样直接改一句话，
 - 必须重新执行 Embedding 流程并更新数据库。

目录形态 vs 向量化：场景决定选择



维度	 本地 MD 目录 (结构化文本)	 高维向量化 (Vector DB)
可读性	极高 (直接可编辑)	极低 (浮点数黑盒)
检索机制	精确匹配、文件路径路由	语义相似度、Top-K 召回
维护成本	极低 (任意编辑器即可)	较高 (需维护 Embedding 模型)
最适用场景	核心 Prompt、全局画像、系统规则	单次历史对话、海量历史轨迹

结论：现代 Agent 往往采用**混合架构 (Hybrid)**
——用 MD 存核心且需人工维护的规则与画像，用向量库存海量对话轨迹 / 执行日志。



轨迹会封存，记忆会跨会话累积；技能 = 从多次成功决策中提炼的标准化流程（SOP），是记忆的产物，会被不断复用。



智能体需要类似人脑的机制：工作记忆满后提炼至短期，再升华至长期。

从人脑到 AI：记忆机制的类比



人脑的记忆

感觉记忆

秒级暂存：感官输入的缓冲



工作记忆

正在思考的事：容量有限的加工台



长时记忆

经验与自我：终身累积，越用越聪明



AI 的记忆

上下文窗口

当下输入：当前对话的 4K–128K tokens

会话缓存

本次会话的历史：会话结束即清空

时序记忆树

跨会话持久化：主题摘要 → 趋势 → 画像

不是在造数据库，是在给数字生命体造「海马体」。

知识记忆 (Knowledge)


- **本质：** “世界是什么样的”
- **隐喻：** 海马体 / 档案馆
- **形态：** 事实 · 偏好 · 经历 · 文档
- **示例：** “用户喜欢深色模式”
- **作用：** 提供决策素材

规则与技能 (Rules & Skills)

- **本质：** “遇到事情该怎么做”
- **隐喻：** 基底核 / 工具箱
- **形态：** SOP · 脚本 · 函数调用
- **示例：** “画图就调用 SVG 工具”
- **作用：** 约束并驱动行为

互生关系： 知识为技能提供 “决策素材”， **技能**基于知识执行 “落地动作”

时序分层：从碎片到画像



聚合方向



查询展开

任务轨迹沉在底层，逐层聚合，升华为跨会话记忆

参考文献： [1] [2601.02845] TiMem: Temporal-Hierarchical Memory Consolidation for Long-Horizon Conversational Agents (时序分层记忆：面向长程对话智能体) . ACL 2026.

日常记录 → 每周总结 → 长期画像：每日自动归档，每周自动摘要，画像增量更新。

记忆不是仓库：写入 - 读取的完整代谢




写入路径：像新陈代谢，层层提纯



信息密度递减 → 抽象层级递增（层层提纯）

存什么：原始对话 → 向量库 | 摘要 → 结构化 JSON | 画像 → Markdown

读取路径：按需展开，组装上下文




画像反哺读取：越用越懂你

记忆不是存进去就完事，而是「写入 → 发酵 → 提纯 → 召回」的完整代谢。

记忆重塑：召回后的整理



我的 KNN 的参数修改决策历史？



搜出来还不够，要筛选才有效——召回只是第一步，过滤整理才决定上下文质量。

记错了怎么办：记忆的冲突处理



上周的记忆

我在调 KNN 聚类，K=5 效果最好，先沿这条路线做。



今天的记忆

KNN 对异常值太敏感，改用密度聚类 DBSCAN 试试。

系统如何发现矛盾？

新记忆与历史画像做语义比对，若语义冲突且时间跨度大 → 触发冲突检测

① 打时间戳，新覆盖旧

默认策略：新记忆优先。

上周说沿 KNN 路线做，今天改试 DBSCAN——以今天的决定为准。

② 保留两者，标注「观点变化」

不覆盖、不删除，

把矛盾本身记成一条记忆：课题路线从 KNN 转向密度聚类——画像随之更新。

③ 让大模型裁决

结合更多上下文判断：

是「一次实验受挫」还是 路线真实切换？


裁决结果决定写入方式。

实验会失败，路线也会调整；记忆系统的价值在于能发现「方向变了」，并跟着课题一起更新。

03

方案选型与跨智能体共享

市面方案横评 · MCP 协议 · 统一记忆云



市面上的记忆方案，怎么选？



方案	时序分层	自动摘要	中文支持	MCP 支持	一句话定位
Mem0	版本时间戳	需自定义	英文为主	✓	API 简洁，动手环节用它
Zep	时间图谱	原生支持	英文为主	✓	企业级会话上下文记忆
Letta	核心 / 归档	需自定义	英文为主	✓	原 MemGPT，虚拟内存类比
TiMEM	原生支持	原生支持	中文优先	✓	时序分层记忆引擎，支持私有化部署



按核心诉求选型：快速体验选 Mem0，复杂关系推理选 Zep，长周期连续任务看时序分层类方案。

有记忆 vs 无记忆：真实对比



跳出播放记忆横评录屏

❌无记忆（原生新会话）

KNN 实验，Iris 数据集，K=3，准确率只有 82%

可能由多种因素导致，比如特征缩放不足或 K 值选择不当。

(重开窗口) 刚才那个问题，先标准化会不会好点？

标准化通常有帮助，请问你具体在用哪个数据集？

完全断片，反复询问已提供的信息

差异：通用 vs 专属

✅有记忆（接入记忆服务）

KNN 实验，Iris 数据集，K=3，准确率只有 82%

记住了。Iris, K=3, 82%。你试过调整 K 值或特征缩放吗？

(重开窗口) 刚才那个问题，先标准化会不会好点？

针对你 Iris 上 82% 的问题：KNN 对距离敏感，标准化后权重一致，很可能有效。


指代消解成功，上下文继承，专属建议

接入记忆引擎后，AI 的回答从 "通用模板" 变成了懂你上下文的 "专属建议"。

MCP：跨智能体的“神经系统”



跳出配置 MCP 接入演示



没有 MCP：每个助手各记各的，换一个就失忆；有了 MCP：所有助手共用同一份记忆服务——接入仅需服务地址 + 访问密钥。

记忆引擎系统界面示意



我今天准备讲解关于智能体Age AskT

我如果做KNN演示，应该召回哪些记忆



AskT

TiMEM 已召回 3 条记忆，正在结合这些背景回答：

[1] L1 · 2026-09-06 1...

[2] L1 · 用户计划在2026-09...

[3] L1 · 用户在2026-09-0...

[2] L1 · 片段 记忆

2026-09-06T06:48:02.276735+00:00

用户计划在2026-09-06 14:48当天面向中科院科研工作者讲解智能体Agent Memory和知识库RAG相关知识，讲解案例为KNN算法，还需要一个能演示参数设置记录变化和决策过程的记忆流。AskT未召回相关记忆流内容，随后提出可以创建一个Python语言的简单记忆流示例来辅助讲解。

#chat #assistant

来自 AskT

详情弹窗 →

记忆重塑

召回 3 条 → 整理为记忆脉络

- [1] L1 · 片段 2026-09-06 14:50，用户询问使用KNN时需要注意什么。AskT表示未从记忆或知... ✓ 保留
- [2] L1 · 片段 用户计划在2026-09-06 14:48当天面向中科院科研工作者讲解智能体Agent Me... ✓ 保留
- [3] L1 · 片段 用户在2026-09-06 14:49提到，刚刚测试记忆时发现科研场景下的提问召回了不相关的... ✓ 保留

整理后的记忆脉络（不直接回答当前问题）：

用户计划讲解KNN算法，测试记忆时发现科研场景提问召回不相关片段，还询问KNN注意事项。

准确

有偏差

反馈将用于训练记忆专用模型

问问你的记忆... 输入@选择知识库

TiMEM 已写入新记忆

L1 · 片段

用户在2026-09-06 14:51询问如果进行KNN演示应该召回哪些...

今日协作时间轴

14:48 - 14:50 跨 2 分钟

收起片段

L2 · 主题 3 条片段记忆聚合

2026-09-06科研讲解相关沟通

2026-09-06 14:48，用户计划当天面向中科院科研工作者讲解智能体Agent Memory和知识库RAG知识，案例用KNN算法，还需要演示参数与决策过程的记忆流，AskT未召回相关内容，提议创建Python简单记忆流示例。14:49，用户反馈科研场景提问召回不相关记忆片段，AskT表示未获取到相关记忆与...

#记忆

L1 用户询问KNN使用注意事项及AskT回应

2026-09-06 14:50，用户询问使用KNN时需要注意什么。AskT表示未从记忆或知识库中获取到相关内容，此次回答未引用记忆或知识库。AskT还提到，此前提供的Python实现的简单记忆流示例...

L1 科研场景记忆召回异常及建议

用户在2026-09-06 14:49提到，刚刚测试记忆时发现科研场景下的提问召回了不相关的记忆片段。AskT在同一时间表示未从记忆或知识库中获取到相关内容，此次回答未引用记忆或知识库，并建议用户明确...

L1 KNN算法记忆流演示需求与示例创建提议

用户计划在2026-09-06 14:48当天面向中科院科研工作者讲解智能体Agent Memory和知识库RAG相关知识，讲解案例为KNN算法，还需要一个能演示参数设置记录变化和决策过程的记忆流。A...

13:16 - 13:16 跨 0 分钟

2 条片段

L2 · 主题 2 条片段记忆聚合

统一时间记忆树管理台 + 检索调试台：记忆看得见、查得到、改得了。

跨智能体记忆 MCP+Skill：一份记忆，处处认得你



我的助理

不同的助理，同一个大脑。

忆

同一片记忆云

1位已入驻

还有 8 位等着第一条记忆。

环上是前 8 席，另有 1 席在名单里

已接入

9

已入驻

1 / 9

贡献记忆

1

接入新助理

接入助手

你好，我是接入助手 🤖 集成遇到问题可以直接问我，也可以点下面的常见问题。

怎么接入我的 Agent?

在哪里拿 MCP 配置 / API Key?

支持哪些客户端?

问问集成相关的问题...

席位

teleagent

来自 其他 · 已入驻 · 1 条记忆

配置 断开

Hermes


配置已就绪 · 等第一条记忆

教程 配置 断开

豆包

来自 MCP · 配置已就绪 · 等第一条记忆

配置 断开



Skill = 使用规则：定义何时读记忆、何时写记忆

统一记忆让不同智能体共享同一份认知——换个助手，它依然认识你。

跨智能体记忆 MCP+Skill：Agent 的“网盘”



统一记忆让不同智能体共享同一份认知——换个助手，它依然认识你。

04

应用场景：科研 · 工业 · 教育

先看界面与效果，再看能力与架构





科研文献检索

- 上传大量 PDF
- 自动向量入库
- 检索问答、有据可查



实验过程追踪

- 全程记录调参代码
- 跨天追踪回忆
- 基于前情给出连贯建议



办公提效

- 多助手无缝协同
- 调用统一的记忆库
- 自动生成精准周报

小结：科研流程各环节，用知识库还是记忆？

文献调研 → **知识库**

查得到 · 有引用

实验过程 → **记忆**

记得你 · 跨天连续

数据分析 → **知识库 + 记忆**

代码入库 · 过程入记忆

论文写作 → **两者协同**

引用靠库 · 风格靠记忆

静态资料用知识库（查得到），动态过程靠记忆（记得你）——底层是同一个统一记忆引擎。

工业诊断：图谱与诊断助手 · 界面与能力



工业智能报警分析平台
INTELLIGENT ALARM ANALYSIS PLATFORM

09:42 吸收塔 T-101 压差高报警

09:38 再生塔 T-201 液位低报警

09:31 闪蒸罐 D-301 温度异常

后端正常

12

AI 诊断

王工程师
工艺工程师

功能模块

统计看板

报警列表 12

图谱可视化

AI 诊断助手

记忆引擎

数据上传

帮助中心

Neo4j 图库 已连接

LLM 服务 运行中

记忆引擎 待连接

ALARM RECORDS

报警列表

共 64 条记录 · 已加载 50 条

搜索测点 / 描述 / 内容...

班组级 分厂级 总厂级 全部状态 未确认 已确认 已恢复

测点	描述	工艺单元	报警时间	级别	状态	操作
☐ AI_3231B	烟气O2含量	蒸汽及凝结水系统	2025-10-27 11:13:08	分厂级	未确认	分析
☐ AI_3231B	烟气O2含量	蒸汽及凝结水系统	2025-10-27 11:13:08	分厂级	未确认	分析
☐ LI_2306_3	排污集水池远传液位检测	污水处理系统	2025-10-27 09:58:00	班组级	未确认	分析
☐ LI_2306_3	排污集水池远传液位检测	污水处理系统	2025-10-27 09:58:00	班组级	未确认	分析
☐ FIC_1430B	FIC_1430B锅炉水增压泵B流量计调节	硫磺回收单元	2025-10-25 14:25:59	班组级	未确认	分析
☐ FIC_1430B	FIC_1430B锅炉水增压泵B流量计调节	硫磺回收单元	2025-10-25 14:25:59	班组级	未确认	分析
☐ FI_2601	生活污水远传流量检测	全厂给排水管网系统	2025-10-22 21:09:28	班组级	未确认	分析
☐ FI_2601	生活污水远传流量检测	全厂给排水管网系统	2025-10-22 21:09:28	班组级	未确认	分析

实时数据接入

DCS 点位与报警日志统一接入

专家经验图谱

故障→根因→处置 结构化沉淀

时序轨迹记忆

运行节律与劣化趋势沉淀成画像

诊断助手预判

相似故障 + 画像，提前预警

没有记忆，AI 只看到「当前正常」；有了记忆，AI 发现「这是三个月前那次爆管的前奏」。

工业诊断：化工厂液罐监测



无记忆 vs 有记忆：对比效果

无记忆 Agent x 62°C < 65°C 阈值 → 判断「正常」，无需处理——只看此刻，不看历史	有记忆 Agent ✓ 与 3 个月前爆管前 72h 曲线相似度 87%，叠加专家经验 → 黄色预警，建议提前巡检	效果变化 判据：单点阈值 → 趋势相似度；行动：事后响应 → 提前预判
---	---	---

从「人盯屏幕」到「记忆驱动诊断」——每一次处置都沉淀为可复用的专家经验。

教育陪伴：界面效果与学生画像



多源数据汇聚
三源统一接入

成长画像构建
多维标签持续更新

偏好演化追踪
冲突检测标注「转向」

个性化发展推荐
岗位匹配有据可依

◆ 画像背后：四年偏好演化轨迹



教育陪伴：学生成长画像



◆ 无记忆 vs 有记忆：对比效果


无记忆 Agent x 每次对话都重新问「你想做什么」，推荐靠猜——四年相处等于零	有记忆 Agent ✓ 基于四年演化轨迹直接推荐技术产品经理岗位，匹配度92%，推荐有据可依	效果变化 评价：结果评价 → 过程陪伴；画像：静态标签 → 演化画像
---	--	--

从结果评价到过程陪伴——记忆让每个学生都被真正「看见」。


05

展望与总结

记忆的未来方向 · 核心认知 · 资源与作业



下一步：把记忆“长”进模型参数里



面临三大挑战：

🔒 隐私边界

🗑️ 遗忘机制

⚡ 冲突消解

短期内外挂记忆更灵活可控，但长远趋势是让记忆伴随协作持续“长”进模型参数里。

今天带走的 7 个核心认知



RAG = 知, 记忆 = 记

知识是公共的, 记忆是个人的



轨迹 ≠ 记忆 ≠ 技能

颗粒度与时间跨度各不相同



时序分层避免信息过载

碎片 → 摘要 → 周报 → 画像



记忆重塑与过滤

召回不是终点, 提纯才是关键



四大平台各有侧重

Mem0 灵活, TiMEM 主攻时序分层



MCP 实现跨智能体共享

打通孤岛, 一次记住, 处处可用



你的成果: 专属助手

代码很简单, 工程落地是硬功夫

课后作业: 为自己的研究方向设计 RAG + 分层记忆 + 跨系统共享方案草图


将这七条原则作为自检清单: 知识库、分层机制与跨工具共享是智能体记忆的核心。

课后作业：做出你的有记忆助手



任务零 (5') RAG 体验

向聚类综述 PDF 提问
=> 会查文献的助手




任务一 (10') 写入记忆

用记忆服务写入记录
=> 有实验记录的库



任务二 (8') 分层聚合

生成每日摘要、画像
=> 周报 + 画像



任务三 (6'+3') 集成问答与展示

投屏分享
=> 你的专属助手

课后按四个渐进任务完成，代码与清单见课后资源页，课程群内集中答疑

四个渐进任务由浅入深——完成后，你就拥有一个专属的有记忆问答助手。