

Harness 实训：构建科研数据 Harness —— 从科研文献到可信的 AI-Ready 数据集

张健

中国科学院大学天文与空间科学学院

国科大他山协会

2026 年 9 月

为什么需要领域数据集？


- ◆ 快速全面了解一个新领域，或为熟悉的领域撰写综述
- ◆ 需要全面、及时、维护良好的数据集

案例：Open Astronomy Catalogs

- ◆ 设想：每个子领域由社区自发维护数据库，通过 GitHub 协作提交、入库新研究
- ◆ 困境：数据提交与整理入库依赖专家大量重复劳动，运维难以为继，核心发起者离开后项目停止维护
- ◆ 现状：仅 TNS、开放系外行星数据库等热门领域依靠成熟组织与资金存活，冷门子领域的缺口始终存在

本质上是经济问题而非技术问题

AI 将专家重复枯燥的智力劳动，压到 API 账单的价格



Open Astronomy Catalogs
由社区自发维护的天文数据库群

方法一：单轮聊天机器人交互



做法：上传论文 PDF ，一句话说明提取需求，单轮交互即可获得答案【演示见下图】

优势：简单、直接、零门槛，适合零散的临时提取

缺陷：需手动提供资料、手动整理结果，自动化程度最低

① 交互开始：上传论文，提出提取需求

 Liao_2024_AJ_16...
PDF 681.84 KB

 2504.14836v1
PDF 22.91 MB

帮我将这两篇文章里提到的可能unbound的高速星提取出来

 思考已完成

我先读一下这两篇论文的内容。

阅读 | Liao_2024_AJ_167_76.pdf

文件阅读失败

• 思考已完成

第一篇已读完。第二篇文件太大，我用命令行提取文本。

将两篇高速星论文交给 AI ，要求提取其中可能 unbound 的候选

② 交互结束：AI 返回提取结果

两篇论文中“可能 unbound（非束缚）”的高速星已全部提取出来。

论文一：Liao et al. 2024 (AJ 167:76)

该文从 Gaia DR3 + 各大光谱巡天中选出 519 颗高速星，其中 9 颗非束缚候选体 ($P_{ub} > 0.5$)，参数见原文 Table 2:

表格					
Gaia DR3 source_id	R.A. (°)	Decl. (°)	rv (km/s)	d (kpc)	v_GC (km/s)
1309092223502856576	257.4199	+29.9771	-487±1	16.12 ^{+3.00} _{-2.24}	570 ⁺⁹² ₋₇₀
1204061267883975040	238.1112	+20.1969	-263±1	10.36 ^{+1.77} _{-1.36}	652 ⁺¹⁴⁹ ₋₁₀₃
1297316350890352000	248.1776	+21.2721	-335±1	9.60 ^{+1.33} _{-1.05}	559 ⁺⁸⁸ ₋₇₂
4263403134667526144	292.1825	-0.0883	-25±2	8.44 ^{+1.48} _{-1.04}	694 ⁺¹⁴² ₋₁₀₈

AI 给出候选表格，但结果仍需人工核对与整理



原理：运行在云电脑里的 Agent，自动搜集资料、分析整理，输出调研报告【演示见下图】

优势：无需手动提供资料，一句话即可启动完整调研流程

缺陷：过程不透明、资源受商业限制 → 调研不充分（2018 年至今仅收录 21 条，实际应有上百颗）

① 提出调研需求

帮我调研一下2018年至今发现了多少高速星（HVS），将它们的ID、位置、速度等信息整理成一个文件给我

• 整理星系数据至Excel表格并导出

阅读 SKILL.md

• 澄清需求输出格式与范围

我先确认几个关键需求，以便调研和整理更贴合你的预期。

要求调研 2018 年至今发现的高速星（HVS），并整理 ID、位置、速度等信息成文件；AI 先反问确认需求，再开始自动调研

② 输出调研报告

调研完成，两份交付文件已就绪。

核心结论：按“严格未束缚”标准，2018年至2026年8月共收录 21条个体级确认/声称未束缚的HVS记录——其中唯一无争议的银心SMBH弹射HVS仍是 **S5-HVS1**（ 1755 ± 50 km/s，2019）；最大单批新增来自LAMOST DR10（2025年，LAMOST-HVS5-14 共10颗）；超新星相关通道贡献了速度最快的群体（D6白矮星，总速度1000-3000 km/s量级）。另有12条高概率概率性候选和7条特殊/排除案例（含首个IMBH弹射候选J0731+3717、被推翻的人马座起源宣称J1443+1453）。

交付文件：

- Excel 星表**（已通过全部结构与公式校验）——6个工作表：封面（关键指标与索引）、确认未束缚HVS（21条逐星记录：编号、Gaia DR3 ID、坐标、距离、银心距、速度、未束缚性、起源、年份、来源）、高概率候选（12条）、特殊案例与排除（7条）、巡天统计（12项研究汇总）、数据来源（25条文献链接）。
- 研究报告（Markdown）**——含发现时间线、速度-银心距逃逸曲线图、机制分类图三张插图，以及分层收录标准、各发现详述、概率性大样本统计与讨论，全文附文献引用。

一点说明：LAMOST-HVS7-14 的精确坐标与参数刊于 Sun et al. 2025 (ApJ 986, 22) 表3-4，受原文页面获取限制，星表中这8颗星的速度为读自该文图2的近似值，均已明确标注“见原文表3-4”，未做任何虚构填充。

报告结论明显偏少，且 AI 如何得出该结论并不透明

方法三：使用通用 Agent 进行调研



- 做法：Agent 在本地运行，任务自动拆解为 ToDo List ，并行子代理逐篇提取后汇总【演示见下图】
- 优势：流程透明灵活、资源不受限；子代理的上下文隔离提升提取质量（ 2023 年至今的结果已多于深度研究 2018 年至今的量）
- 缺陷：对单一数据集构建任务过重、结果难以审计；问题定义不严，执行必然漂移

① 任务拆解与并行子代理（WorkBuddy）

我希望你帮我获取arxiv内2023-2026的所有hypervelocity stars相关的文献pdf，逐篇判断其中是否有可能unbound的高速星候选，然后将其中满足要求的候选信息提取出来，最后给我汇总到一个文件里

WorkBuddy 预计消耗 0.3 ~ 3.4

深度思考

我来帮你完成这个任务。这是一个系统性研究任务，我先规划一下步骤：

深度思考

任务列表

- 下载相关论文 PDF
- 正在搜索 arXiv 超高速星论文
- 逐篇分析论文中的 unbound 高速星候选
- 汇总候选信息到单一文件

正在执行命令 · 已消耗 0.36 · 用不到的技能先关掉，少占上下文也更省 Token

下载 arXiv 2023-2026 文献 → 并行提取候选 → 汇总到文件

② 提取结果：出现了偏离约定的条目

2023-2026_超高速星unbound候选汇总.xlsx					
A	B	C	D	E	F
候选体名称	类型	速度(km/s)	距离(kpc)	unbound判定	判定依据/备注
1 LAMOST-HVS5 (J161649.39-030624.9)	A0III	806.1±276.6 (vtot)	7.85±2.20	是	超过当地逃逸速度(MWPotential2014)
3 LAMOST-HVS6 (J171230.82+110924.5)	A9V	627.4±168.5 (vtot)	9.54±2.68	是	超过当地逃逸速度
4 LAMOST-HVS7 (J110108.23+360918.0)	A0III	511.0±59.2 (vtot)	6.61±1.85	是	超过当地逃逸速度
5 LAMOST-HVS8 (J023346.69+103930.7)	A0III	501.6±124.2 (vtot)	8.68±2.43	是	超过当地逃逸速度
6 LAMOST-HVS9 (J125538.89+352338.8)	A1IV	535.6±93.6 (vtot)	14.16±3.94	是	超过当地逃逸速度
7 LAMOST-HVS10 (J015725.24+323539.3)	A0V	758.0±61.3 (vtot)	11.20±0.82	是	超过当地逃逸速度
8 LAMOST-HVS11 (J101018.82+302028.1)	B5V	437.0±4.2 (vtot)	27.29±3.75	是	超过当地逃逸速度
9 LAMOST-HVS12 (J014106.87+163157.3)	B3V	508.7±12.8 (vtot)	37.28±3.42	是	超过当地逃逸速度
10 LAMOST-HVS13 (J212520.96+190802.1)	B9III	796.7±191.7 (vtot)	15.02±3.65	是	超过当地逃逸速度
11 LAMOST-HVS14 (J015022.75+483631.1)	B8V	438.0±16.1 (vtot)	16.33±4.00	是(边界)	超过当地逃逸速度
12 HVS01 (Gaia 3841458366321558656)	贫金属晚型星/CEMP候选	vT=900.8±115.6; vlos=-100.3±8.8	z=1.7±0.2 kpc	是	Pesc=100%(FOR52光谱确认)
13 HVS02 (Gaia 1451652599056932480)	贫金属晚型星	vT=680.1±140.7; vlos=-155.3±5.1	z=2.1±0.4 kpc	是	Pesc高
14 HVS03 (Gaia 4294774301679435776)	贫金属晚型星	vT=628.1±97.6; vlos=-247.1±6.0	z=-0.3±0.1 kpc	是	Pesc高
15 HVS04 (Gaia 524867160580305440)	贫金属晚型星	vT=580.4±45.6; vlos=401.2±6.2	z=-0.4±0.1 kpc	是	Pesc高
16 HVS05 (Gaia 6496426077183248256)	贫金属晚型星	vT=611.0±125.5; vlos=82.8±7.0	z=-2.1±0.4 kpc	是	Pesc高
17 HVS06 (Gaia 5673818825000094336)	贫金属晚型星	vT=549.7±71.2; vlos=234.0±7.3	z=1.3±0.2 kpc	是	Pesc高
18 HVS07 (Gaia 6389682292902592256)	贫金属晚型星	vT=591.8±92.9; 银心近日点710±70	z=-2.8±0.4; min=1.4 kpc	是	唯一可能与银心关联者
19 HVS08-HVS17 (共10颗)	贫金属晚型星	vT=500-600	z=±0.3-3.3 kpc	是	Pesc高(部分依赖势模型)
20 HVS18-HVS23 (共6颗)	贫金属晚型星/RR Lyrae	vT=495-550	-	否	Pesc不足
21 J1300+0256 (Gaia 3692326965681261184)	RRc	vGC=441.1 (v=vesc 385.2)	RG=39.50 kpc	是	唯一3D确认候选
22 Gaia 378807525573579520	RR Lyrae	vGC=1530.9±171.5	D=14.1±1.5	是	切向速度超逃逸
23 Gaia 2644870582050682240	RR Lyrae	vGC=1092.5±86.4	D=18.3±1.3	是	切向速度超逃逸
24 Gaia 4717299539114264320	RR Lyrae	vGC=574.8±122.5	D=69.7±6.4	是	切向速度超逃逸
25 Gaia 4918733303434183296	RR Lyrae	vGC=549.9±127.1	D=73.6±7.8	是	切向速度超逃逸
26 HVS19 - goldilocks 87颗	RR Lyrae	vt 超逃逸(7颗>800,3颗>1000)	可达100 kpc	是	切向速度超逃逸

红色 = 未束缚（unbound） · 绿色 = 束缚（bound）
混入了 bound 条目——Agent 偏离了最初的约定



什么是 Harness ?

- ◆ 著名公式： $\text{Agent} = \text{LLM} + \text{Harness}$
- ◆ Harness 本义「马具」：大模型是力大却难控的烈马，需要一套工程组件约束它，按你的需求完成任务

方法要点

- ◆ 自己定义问题，搭建「文献 → 数据产物」的处理 workflow
- ◆ 程序化验证：每条结果可追溯到原文的具体位置
- ◆ 清晰透明、掌控力最强；代价是搭建耗时（我的项目已连续工作 4 个月以上）

Stella-meta 元 Skill：把我的项目蒸馏成可复用的搭建指南（已开源）

stella-metaPublic

PinWatch 0Fork 0Starred 1

main1 Branch0 Tags

Go to file

Add fileCode

zhang2023-byte docs: make skill installation host-neutral ✓e001660 · 2 weeks ago · 5 Commits

.github/workflows	feat: add portable scientific data harness skill	2 weeks ago
assets	feat: separate harness workflow stages	2 weeks ago
references	feat: separate harness workflow stages	2 weeks ago
scripts	feat: separate harness workflow stages	2 weeks ago
tests	feat: separate harness workflow stages	2 weeks ago
.gitignore	feat: add portable scientific data harness skill	2 weeks ago
LICENSE	feat: add portable scientific data harness skill	2 weeks ago
README.md	docs: make skill installation host-neutral	2 weeks ago
SKILL.md	feat: separate harness workflow stages	2 weeks ago
requirements.txt	feat: add portable scientific data harness skill	2 weeks ago

About

A meta-teaching skill distilled from Stella HVS. Install it locally to build a minimal scientific-data harness for any research field, step by step.

[github.com/zhang2023-byte/stella...](#)

agent-skillai-agentreproducible-researchresearch-workflowscientific-data

scientific-literature

ReadmeMIT licenseActivity1 star0 watching0 forks

github.com/zhang2023-byte/stella-meta —— 内含操作说明书提示词与已测试脚本

实操流程（以高速星为例）

- ① 将 Skill 链接发给 Agent 【最后给出】
- ② Agent 引导你定义问题、确定数据存储模板
- ③ 获取对应文献
- ④ 执行提取


[接下来：手把手实操 →](#)

为什么需要 Benchmark？

- ◆ 用分数直观量化新系统与旧版本、同类竞品的能力差距
- ◆ 知道如何评价一个工作，就知道这个工作该怎么做；
- ◆ 重要 Benchmark 奠定领域基础



ImageNet → AlexNet
(计算机视觉)



CASP → AlphaFold
(蛋白质结构预测)

文献数据提取的三层评价模板

L0

格式层：每篇文章的提取结果是否符合输出格式要求

L1

实体层：提取的科学实体条目与专家结果是否一致

L2

数值层：每个科学实体对应的数值是否准确

核心原则：有效衡量你真正关心的东西！

领域问题往往没有现成 Benchmark，需要自建：为将数据集发表成文，我和合作者花一个多月（人机结合）提取 50 篇文献，构建了高速星提取的 Benchmark，据此量化准确率、召回率等指标



为什么要发布？

- ◆ 同一领域重复构建同一数据库，是对资源的浪费
- ◆ 识别领域最重要的问题，构建好并开放给其他研究者使用
- ◆ 他人免重建即可开展研究，你也能收获领域影响力

数据集的构建原则

FAIR 原则（经典数据科学）


可查找 Findable · 可获取 Accessible

可互操作 Interoperable · 可复用 Reusable


AI-Ready 原则思考（面向未来的 Agent 使用者）

- ① 结构化——便于被其他 Agent 用程序调用
- ② 可追溯——每条数据可回溯原始出处，便于核验
- ③ 有治理——明确说明局限，让 Agent 知道何时、如何使用

案例：我的高速星数据库网站 STELLA HVS Catalog



FAIR 指导原则（Wilkinson et al., 2016, Scientific Data）



1

数据缺口

领域科研数据散落在数十年文献中，缺乏维护良好的垂直数据库

2

方法进阶

网页 Chatbot → 深度研究 →
通用 Agent → 自建 Harness
质量要求不断提高，系统工程不断深入

3

动手实操

以高速星领域为例，用 Stella-
meta 元 Skill 一步步搭建最小
科研数据 Harness

4

评估与共享

用自建 Benchmark 量化质量；
按 FAIR + AI-Ready 原则发布数
据集，供领域共享

Stella-meta



扫码获取 Stella-meta，现场试用

这是一个教学用途的 Skill，目的是让大家完整体会搭建科研数据 Harness 的过程。作为教学示例，它存在一些局限性：

1. 只能获取 arXiv 上的文献并处理 latex；
2. 要提取的数据必须存在于文献内；
3. 数据的结构必须能被组织成「独立 id + 若干数值属性」的格式。

相关 Skill 推荐

TraitTrawler

从文献自动构建带原文证据、确定性验证与审计链的结构化数据库，与 Stella-meta 最接近。

github.com/coleoguy/TraitTrawler

Data Liberation

将 PDF、扫描报告、网页和表格转化为带 Schema、溯源、审计与发布流程的可复现数据项目。

github.com/CUPIDS-Lab/data-liberation-skill

Scientific Data Extraction

针对科研 PDF、表格、图像和曲线，自动选择解析工具并进行结构化抽取与多方法交叉验证。

github.com/jkitchin/skillz · [skills/research/scientific-data-extraction](#)

NASA ADS Skill

面向天文学文献检索、全文获取、版本化缓存、证据定位和可复用本地文献记忆。

github.com/SukiYume/nasa-ads-skill

Literature Review Skill

执行带检索策略、纳入排除标准、数据抽取、质量评价和引用验证的系统性文献综述。

github.com/K-Dense-AI/scientific-agent-skills · [skills/literature-review](#)

Scientific Agent Skills

大型科研 Skill 集合，覆盖文献检索、科研数据库访问、结构化抽取、科学计算和数据分析。

github.com/K-Dense-AI/scientific-agent-skills