

如何构建领域基座模型与 AI Scientist 系统

科学智能进阶


李珣肠

中国科学院大学 天文与空间科学学院

中国科学院 国家天文台

中国科学院大学 他山学科交叉创新协会

人工智能发展历程



如何将科学问题转化为数据问题并解决处理？

- 还不能这样说。这次检验的是它能不能分对类别，没有检验它依据的是不是物理规律——两件事需要不同的检查。

具体到眼前的数字：87.71%（对照全猜多数类的 57.72%）只说明这批曲线和类别编号之间存在可以学习的对应关系。模型可能是抓住了恒星本身的信号，也可能是抓住了曲线形状、亮度幅度，甚至观测和数据处理留下的痕迹。这三者在结果分数上看起来是一样的。

还有一个更直接的限制：这份数据的横轴我们只知道是“采样点”，数据包里没有建立类别的天文名称对应，也没有给出物理时间单位；程序保留了原始数值，没有做周期搜索或相位折叠。所以我们连“它是否找到了光变周期”这个问题都还没检验过。

反过来看那些错例也有意思：865 条真实类 3 被判成类 1，其中 186 条模型给出的最高概率超过 0.9。它很自信地错了，说明它的判断依据和类别的真实定义并不总是一致。但这也不能推出“它没抓到规律”——一个真懂物理的模型同样会分错，而混淆矩阵只告诉你哪些类容易混，不告诉你原因是形状相似还是别的。

要往这一步走，得另做检查，比如看它实际依赖曲线的哪一段、把曲线整体平移或加噪声后判断是否还稳定、再和已有的天文类别定义对照。这些都是新实验，要做的话我们先商量好检查哪一个。



课堂实践

| 基于[提供的skill地址]，我想用[自己的数据地址或课程光变示例][实现分类/参数估计或具体下游任务]。

大量没有专家订正的数据，怎么用起来？

- 我读过 `nanoscigpt/starlight.py` 了，说说现有代码的实际安排。

****关键点：**预训练和分类读的是同一批 800

条训练曲线，区别只在用了哪些字段。****不是**“一部分数据拿去预训练、另一部分拿去分类”。

三份数据各自的用途：

800 条训练曲线（ x 是 800×1024 的数值， y 是对应类别）。预训练循环里只把 x 交给模型算“预测下一段”的损失，完全没有碰 y (`starlight.py:155`)。到了分类阶段，才用 y 把 800 条按类别分成三组做均衡采样，并更新模型参数 (`starlight.py:163`)。同一批曲线，两个阶段读不同字段。

200 条验证曲线。不更新任何参数，但参与“挑哪个检查点”。预训练阶段每 50 步用它算一次预测下一段的误差，留下误差最小的那份权重存成 `pretrained.pt` (`starlight.py:158-162`)；分类阶段用它的宏 F1 挑检查点，并比较三个分支——`scratch`（不预训练直接分类）、`finetuned`（从预训练权重接着分类）、`scratch_long`（不预训练但步数对齐到和“预训练+分类”总更新次数相同）。

8236 条测试曲线。只在最后评价一次，既不更新参数也不参与挑选，跑完写进 `metrics.json` 和 `predictions.npz` (`starlight.py:205`)。



课堂实践

我有[自己的数据地址或课程示例]，其中[有标签数据量]，[没有专家订正的数据量]，最后希望[实现分类/参数估计/生成或预测任务]。

■ 先从语言模型的最小版本开始

先用所有数据学习常见关系，再用少量标签完成具体任务

再试不同的提问内容

同一份微调权重，未在两次提问之间追加训练。

问题	模型实际回答
Why is DNA important?	A chain of amino acids.
Where is a spectrum used?	Light measured by wavelength.
What is a crystal?	A target for a sample.
What is gravity?	A sequence of bases.

模型给出了回答，但这些输出没有正确解释问题所问的用途、原因或概念。




课堂实践

基于 [课程仓库中的Skill]，先运行 [text示例]，再把预训练结果接到 [分类/回归或生成任务]。

不是把科学数据改写成文字，而是保留它原来的关系

同一测试集上的分类结果

StarLightCurves · 8236条测试曲线 · 当前单次运行，不表示多次实验均值



点图横轴局部展开。1100步对照匹配总更新次数，不等于精确匹配计算量。



课堂实践： 基于[课程仓库中的Skill]，采用[光变示例或自己的数据]，先预训练，再做分类。

什么是大模型？

输入预处理


- 编码：高维语义空间表示
- 投影：通用模型可理解空间

通用模型 [广泛数据预训练]


- 知识模型：弥补学习有效视觉表征时

输出后处理

- 解码：特定模态输出





预训练与微调



Eg. 基于数以万计的图像训练模型分类能力

Features learned from training on different object classes.




模型几乎学习到区分所有物体的特征提取与识别能力——> 取其特征提取部分，面向目标任务做适配训练 [如分类、回归]

预训练阶段 [给前序列，补后序列]

Probabilities
over
vocabulary

bread	...	cake	...	dress	...	game	...	salad
0.02	...	0.25	...	0.001	...	0.001	...	0.06

Language
Model



Input from User

To sleep well

Sample a token from
vocabulary

you are


Run LM for the next token

sleep well you


Generate new input

Generated text:

To sleep well you are





<seq>MHLTPEEKSAVTA
LWGKVNVDDEVGGGALG
RLLVVYPYTQRFFESFGD
LSTPDVAMGNPKVKAH
GKKVLGAFSDGLAHLDN
LKGTfATLSELHCDKLHV
DPENFRLLGNVLCVLA
HHFGKEFTPPVQAAYQK
VVAGVANALAHKYH</
seq>





基于序列补全的自监督预训练——> 学习序列特征

微调阶段 [给完整序列，解决任务]



Class=?
Teff=?
Logg=?
FeH=?



基于序列预测的下游任务监督微调——> 学习映射关系

专用模型将单一任务做到极高水准

UniRep/TAPE（2019）建立科学数据中的预训练—迁移范式，ESM-1b/ProtTrans（2021）完成规模化数据验证；但每个下游任务仍然需要单独训练、存在表征不可复用的瓶颈。

领域	代表工作	输入→输出	架构	核心创新
 蛋白质	ESM-2/ESMFold	氨基酸序列 → 三维结构	Transformer	氨基酸排列的规律更真的藏着结构信息：只用序列就能推出结构
	RFdiffusion	想要的形状/功能 → 新蛋白质序列	RoseTTAFold + 扩散	反过来用：按约束“画”出全新的蛋白质
 天气	Pangu-Weather	当前全球气象场 → 未来几天气象场	3D Transformer	一次性预报全球天气，速度和精度接近传统数值预报，成本远低于后者
	GraphCast	当前全球气象场 → 未来10天气象场	图神经网络	网格点即图节点，多数预报指标超过传统方法
 材料	GNoME	晶体结构 → 稳定性判断	图神经网络	学过几百万种已知晶体后预测新结构，一轮一轮扩充候选库
	CHGNet	原子位置 → 能量和受力	图神经网络	学过大量原子运动轨迹后，替代昂贵的第一性原理计算



蛋白、天气、材料各自出现优秀专用模型 | 架构开始适配科学数据本身的形状（序列、网格、图）

专用模型的成功让人追问：一套预训练特征能不能服务多个下游任务？

ClimaX (2023) 第一次把 foundation model 这个名字带进科学领域，一套天气气候表示服务多类任务。




领域	代表工作	输入 → 输出	架构	核心创新
 生物	AlphaFold3	序列 + 分子组成 → 复合物三维结构	Transformer + 扩散模块	蛋白质、DNA、RNA、小分子统一进一个模型
	scGPT / scFoundation	单细胞基因表达谱 → 细胞类型/扰动响应	Transformer	基因当“词”、细胞当“句子”，几千万细胞上预训练
 地球系统	NeuralGCM	大气状态 → 天气到气候的模拟	物理方程 + 神经网络	物理管大尺度、网络管小尺度，可微分地拼在一起
	GenCast	当前气象场 → 未来15天概率预报	Transformer + 扩散	从“一个确定答案”走向“一组可能路径及概率”



输入输出从单任务走向多任务复用 | 科学数据的不同形状对应不同架构选择

同一套预训练表示，开始接到更多任务，也开始直接生成候选

2024年已经证明不同科学对象可以预训练；2025年更关心这些表示能否跨任务使用，能否从“判断”进一步走到“生成”。



预训练模型不再只提供特征：它开始承担多任务预测、条件生成和跨数据域模拟。


跨模态、跨分布、跨对象

跨模态 | 同一对象有多种测量


跨分布 | 同一对象来自不同物种、组织、数据集或实验平台

跨对象 | 分子、蛋白质、细胞和其他科学对象进入共同表示

跨模态




多模态生物分子与表达对齐



AlphaGenome | 1 Mb DNA序列 → 表达、染色质、剪接和接触图等功能轨道
| U-Net式卷积网络+Transformer | 长序列、多模态融合、单碱基分辨率

MAMMAL | 蛋白质、小分子和基因表达 → 分类、回归或生成结果
| T5式Transformer | 多种生物医学数据共用序列接口

跨分布



Evo 2 | 长DNA序列 → 功能预测或新序列生成

| StripedHyena 2长序列建模 | 覆盖生命三域，最长约一百万个碱基


UCE | 单细胞表达谱 → 共享的细胞表示

| Transformer | 不同组织、物种和实验进入同一表示空间

CAPTAIN | 单细胞RNA与表面蛋白 → 细胞表示和蛋白丰度

| 双编码器Transformer+交叉注意力 | 联合学习跨组织、物种与平台的RNA-蛋白关系

跨对象



BioMatrix (预印本) | 分子与蛋白质的序列、结构和文字 → 理解或生成结果

| 自回归Transformer | 不同生物对象进入共同离散词表

LOGOS (预印本) | 多类科学对象及空间接触关系 → 统一token序列

| 自回归Transformer | 不同任务统一为预测下一个token




不只是把模型做大，而是扩大同一模型能够读懂、迁移和生成的科学对象范围。

从 GOTTA 到 Virtual GOTTA


硬件协同决定能否更早看见；公共数据层决定已公开信息能否更快形成证据。

GOTTA：硬件协同



硬件观测记录
→
时间证据组织

Virtual GOTTA：公共数据层





 **GOTTA:** 硬件阵列 + 统一调度 → 真实 cadence

 **Virtual GOTTA:** 公开光变报告 + 目标级时间点 → 等效间隔

Virtual GOTTA 不是 GOTTA 的硬件复制，而是把多巡天公开光变报告转化为目标级时间证据。

从语言模型到跨波段、跨巡天观测语言

序列模型学习的是 token 在上下文中的约束关系；瞬变源公共报告也可以组织成目标级观测时序上下文。




词序列 → 语义上下文

氨基酸序列 → 结构上下文

跨波段、跨巡天观测序列 → 目标级观测时序上下文

Virtual GOTTA 基座模型：从公共报告学习观测语言

只读取决策时刻前已公开的测光报告，学习时间、亮度、波段、来源和探测状态关系。



公共测光信息流 → 当前证据状态 h_t

SN Clock: 在观测语言表示上约束爆发年龄

当前证据状态 h_t 可转化为爆发年龄分位数，在稀疏公共报告下形成可量化的时间证据。


SN Clock Downstream Model

当前证据状态 $h_t \rightarrow$ age quantile head $\rightarrow$ 爆发年龄约束


输入：当前证据状态



中间：SN Clock age head



输出：爆发年龄分位数



结果 1：极早期稀疏报告

0.873 d

2–3 detections MAE



结果 2：无红移上下文

0.953 d

without redshift context MAE



结果 3：公共信息流效率

1.21 d

full public stream effective cadence

稀疏公共测光报告仍可提供爆发时间约束。

模型已经跑通，下一步怎样迭代优化？

主要变化在 1 类和 3 类的混淆上：

```
flat finetuned:  
[[28, 0, 2],  
 [ 0, 55, 0],  
 [13, 0, 102]]
```

```
mean_last finetuned:  
[[27, 0, 3],  
 [ 0, 55, 0],  
 [11, 0, 104]]
```

也就是说，mean_last 少把 2 个 3 类错判成 1 类，但多错了 1 个 1 类。2 类还是全对。

我的判断：这个结果支持“flat 分类头可能不是最稳”的猜想，但不能说已经证明原问题就是过拟合。因为提升只有 +0.0036 macro-F1，而且只有一个 seed。更有意思的是，mean_last 的 scratch 和 scratch_long 都比 flat 差，只有 finetuned 略好，所以现在更像是：预训练学到的曲线表示配合小分类头有一点帮助，而不是小头本身一定更强。

运行记录我放在 `out/research-p9/research-log.md`。本轮只用了 `train-validation-only.npz`，没有用测试集选方案。




从模型迭代到计算研究

模型迭代已经完成的部分

围绕已有模型提出改动、运行实验、比较结果，并决定下一轮怎样调整。

StarLightCurves validation macro-F1 by readout head



课堂实践

基于 [课程仓库中的 Skill]，围绕刚才训练的模型，基于 The AI Scientist 完成计算环境中的研究流程。

从单一路线到多路线研究

多路线研究树

研究过程的形状：一个问题 → 多条可运行路线 → 各自实验 → 同一方法比较 → 保留、合并或停止

已完成的单一路线

中间有一个小失败：第一次导出预测例子时脚本找不到 `nanoscigpt.starlight`，我修了导入路径后重跑成功，并写进了记录。校验也过了：JSON 可解析，预测文件字段正常，`tests/test_starlight.py` 是 7 passed。



后面我建议先做**错例/机制分析**，暂时不要继续发明新 head：看看 flat 错但 `max_last` 对的那些验证曲线长什么样，以及 `max_last` 剩下 5 个错例有没有共同特征。这样能解释为什么 max pooling 帮到了 1 类/3 类边界。



课堂实践

基于 [课程仓库中的Skill]，围绕刚才的研究问题，用多路线研究树设计并比较多条研究路线。


实验结果自动返回，机器据此规划下一轮

年份		代表工作	科学问题	系统怎样工作	核心创新点
2004		Robot Scientist	根据酵母实验判断候选基因功能	提出候选解释 → 安排实验 → 测量生长结果 → 判断假设	第一次把假设、实验和结果判断接成一条可重复运行的路线
2009		Adam	寻找酵母代谢过程中尚未确定的基因功能	从知识库提出假设，自动配置培养实验，读取生长曲线并筛选解释	从一次原型推进到能够反复开展功能基因组研究的自动系统
2015		Eve	从已有药物中寻找被忽视疾病的候选药物	化合物筛选 → 命中确认 → 建立活性关系 → 选择下一批化合物	上一轮筛选结果开始直接改变下一轮测试对象
2016		ARES	寻找能够达到目标生长速率的碳纳米管制备条件	设置温度和气体参数 → 生长碳纳米管 → 原位测量 → 更新实验条件	将这种做法从生物实验扩展到材料制备，测量结果直接成为下一轮合成条件
2020		Ada	优化薄膜材料的光学和电子性质	调整组成与制备条件 → 制备薄膜 → 自动表征 → 更新下一组条件	将制备、表征和模型判断接入同一套固定式实验平台
2020		Mobile Robotic Chemist	从多种配方中寻找性能更好的光催化剂	在实验台之间移动 → 配制样品 → 操作仪器 → 测量产氢性能 → 选择下一组配方	不再依赖一条专门定制的固定流水线，移动机器人可以使用现有实验设备
 2004—2015 机器人科学家： 假设、实验和判断相连 →  2016 自主材料实验： 测量结果直接修改制备条件 →  2020 自驱实验室： 多台仪器和移动机器人进入同一研究过程 结果返回下一轮					

从一个研究目标出发，查资料、做计算、安排实验并读取结果

过去的自动化实验通常从预先写好的任务和优化程序开始；大语言模型加入后，系统开始理解自然语言提出的研究目标，并选择相应的文献、代码、数据库和实验设备。

年份	代表工作	科学问题	系统怎样工作	核心创新点
2023	 Coscientist	根据自然语言要求规划并完成化学实验	检索资料 → 阅读仪器说明 → 编写实验步骤 → 调用移液设备或云实验室 → 读取实验结果	大语言模型不再只回答化学问题，而是能够在资料、代码和实验设备之间选择下一项操作
2023	 AI-Chemist “小菜”	利用火星陨石中的元素寻找制氢催化剂	理论计算和已有数据提出配方 → 移动机器人调用14个工作站 → 合成、表征和测试 → 根据结果继续筛选	将理论计算、机器学习和真实材料实验放进同一研究过程，从三百多万种可能组成中逐步筛选候选
2024	 ChemCrow	完成涉及检索、计算、反应设计和安全分析的化学任务	理解化学问题 → 从18种专业工具中选择合适工具 → 填写调用参数 → 汇总工具返回结果	将大语言模型掌握的化学知识与可核查的专业工具分开，计算和查询不再只依赖模型直接回答
2024	 SAMPLE	寻找热稳定性更好的蛋白质序列	模型设计蛋白序列 → 自动合成基因并表达蛋白 → 测量酶活性和热稳定性 → 根据测量结果设计下一批序列	将自动实验从材料和化学扩展到蛋白质工程，连续运行多轮“设计—实验—测量”



结果开始改变假设和研究路线

早期自动实验主要围绕固定目标调整配方、参数和实验条件；这一阶段开始把文献、假设、计算、实验结果和后续问题放在同一个研究过程中迭代。

年份	代表工作	科学问题	系统怎样工作	核心创新点
2025	 StarWhisper Telescope	从巡天图像中发现瞬变源并及时安排后随观测	生成观测计划 → 控制望远镜 → 实时处理图像 → 发现候选天体 → 触发后随观测建议	将AI Scientist接入真实望远镜网络，观测结果能够直接改变后续观测安排
2025	 Virtual Lab	设计能够结合新冠病毒变体的纳米抗体	首席研究员Agent组织不同专业Agent讨论 → 调用ESM、AlphaFold和Rosetta → 多轮修改设计 → 人类研究者进行实验验证	不同专业角色围绕同一问题反复修改设计，并由人类研究者完成实验验证
2026	 Co-Scientist	从已有文献和实验线索中提出新的生物学假设	多个Agent生成、批评、比较和修改假设 → 筛选候选方案 → 交由实验验证	不再只执行一条预定路线，而是让多个候选假设竞争并随证据不断修改
2026	 Robin	寻找干性年龄相关性黄斑变性的候选治疗方案	检索文献 → 提出药物候选 → 分析体外实验结果 → 提出RNA测序实验 → 根据新数据修改机制假设	将前一轮实验结果带入下一轮问题，连续推进候选药物、验证实验和机制分析







StarWhisper Telescope(SWT)




星语 3.0[2023]
大模型首次接入天文望远镜






天文多模态得分第一 超过
ChatGPT4o (2024)

模型	平均	星系天体物理学	宇宙学非星系	高能天体物理	天文仪器和方法	太阳和恒星物理学
Ours-7B	0.6326	0.6289	0.5315	0.6273	0.7356	0.6396
GPT4o	0.6167	0.5979	0.5225	0.6364	0.6782	0.6486
InternVL2-40B	0.5548	0.5567	0.5676	0.5545	0.5402	0.6216
InternVL2-26B	0.5193	0.5155	0.4505	0.4505	0.5747	0.5856
InternVL2-8B	0.5082	0.4536	0.5045	0.5045	0.5747	0.5135
GLM-4V-9b	0.5060	0.5052	0.4054	0.5273	0.5862	0.5225
Cambrian_34b	0.5040	0.5155	0.4685	0.4455	0.5862	0.5856

星语 4.0 : 大模型驱动近邻星系
巡天项目 [2024], 完善规划 -
执行 - 报告闭环 [2025]




星语 5.0+ : 科学级望远镜的具身智能化改造



同一个科学问题，需要模型和研究过程共同完成

A 科学基座模型的发展



科学数据怎样表示？模型可以预测、生成或模拟什么？

B AI Scientist的发展



模型和工具怎样进入研究？结果返回结合人类反馈，下一步怎样调整？

需要分清的两件事

- 1 只有一个明确任务和可靠标签时，专用模型可能已经足够。
- 2 没有能够返回并改变下一步的结果时，只完成了工具执行，还没有形成持续研究。



科学基座模型让同一批无标签科学数据能够服务更多任务；AI Scientist让模型结果重新回到计算、实验和观测中，并据此继续迭代研究。



• 团队核心成员



- 他山致力于构建跨学科生态，通过完善的上下游渠道搭建、学生认知普及、内部人才培养、商业孵化与支持等生态链支撑，推动自下而上的学科交叉融合发展与人工智能在科研中的应用，赋能未来科技领军人才的培养与成长。
- 只要有这样的理念：永远链接第一线的人才，第一线的资讯，永远保持辩证思维，保持对各领域发展的敏感度，我们就永远在最时代发展这个快车的车厢里。
- 以人为本，人永远是梦想的最终目的，不是完成某个事情的手段，更不是工具。